FACULTAD DE MEDICINA
UNIVERSIDAD DE CHILE

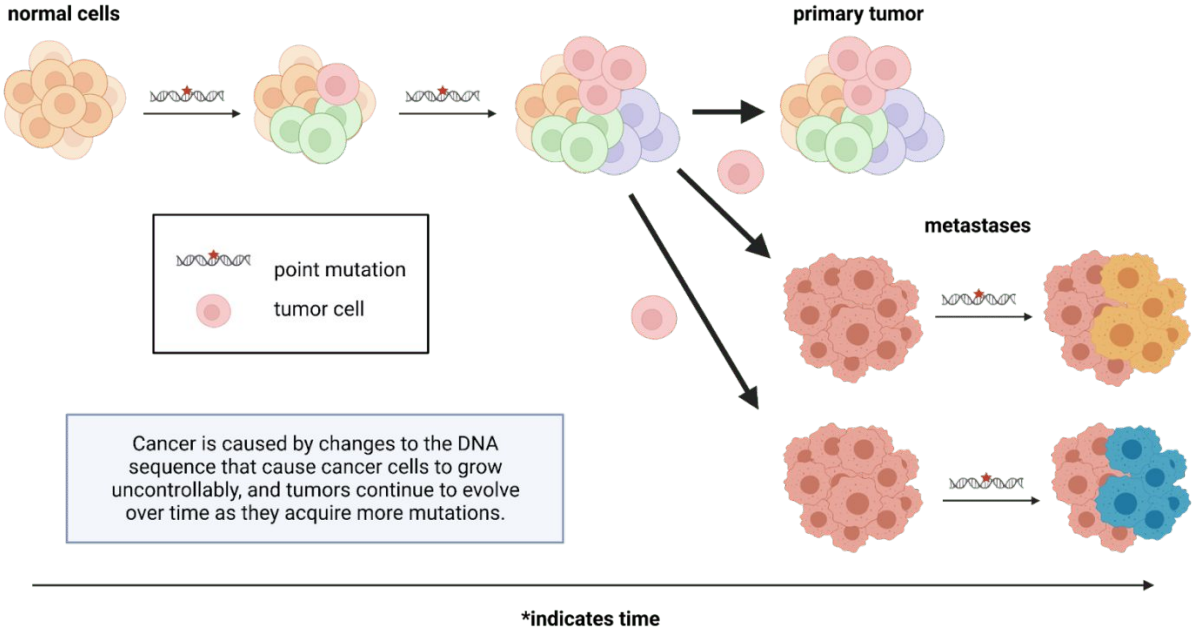
Magíster en Informática Médica

Análisis de genomas de cáncer

Noemí Gómez
13 de octubre, 2026

noemi.gomez@postgrado.uoh.cl

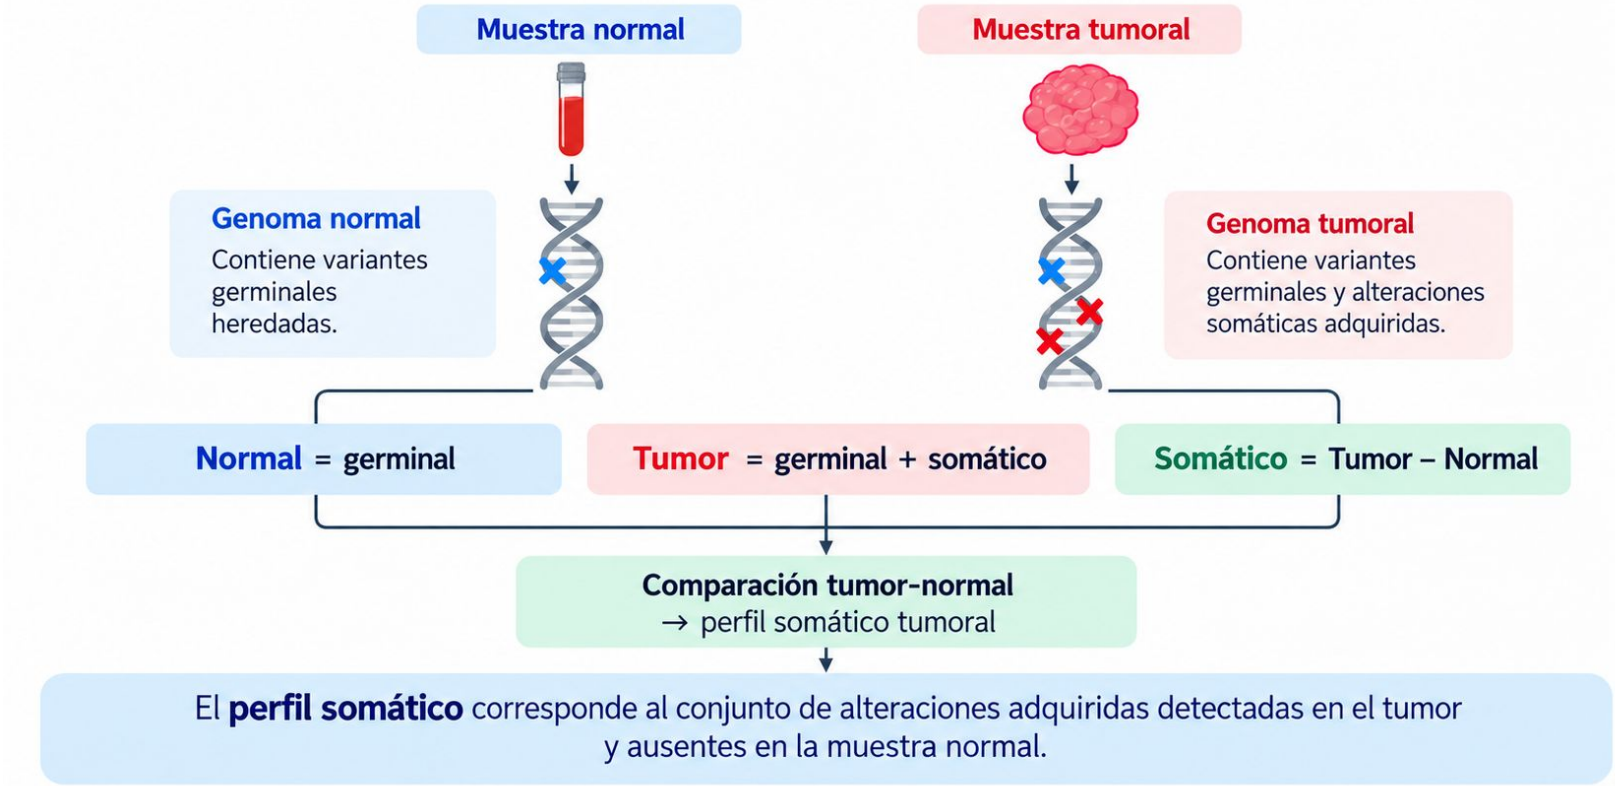
¿Por qué analizar el genoma en cáncer?



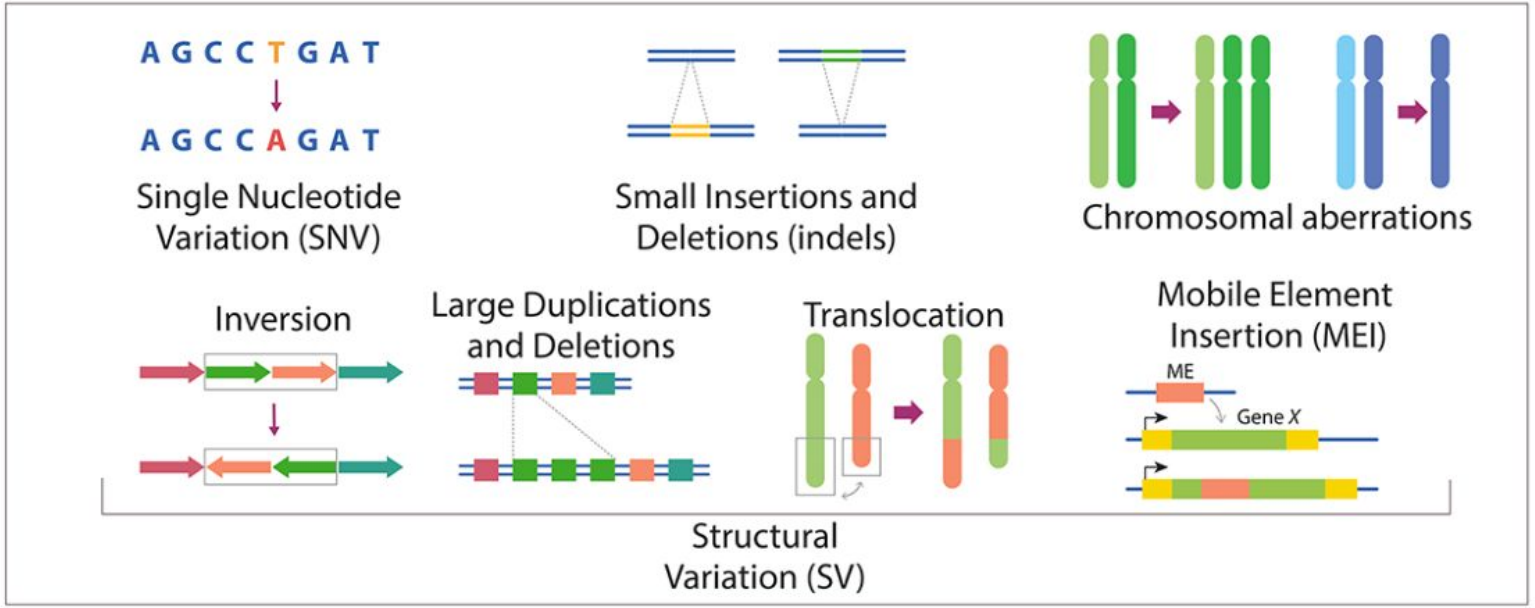
El cáncer es una enfermedad del genoma

Durante su desarrollo se acumulan alteraciones genéticas que modifican el funcionamiento celular y contribuir al desarrollo tumoral

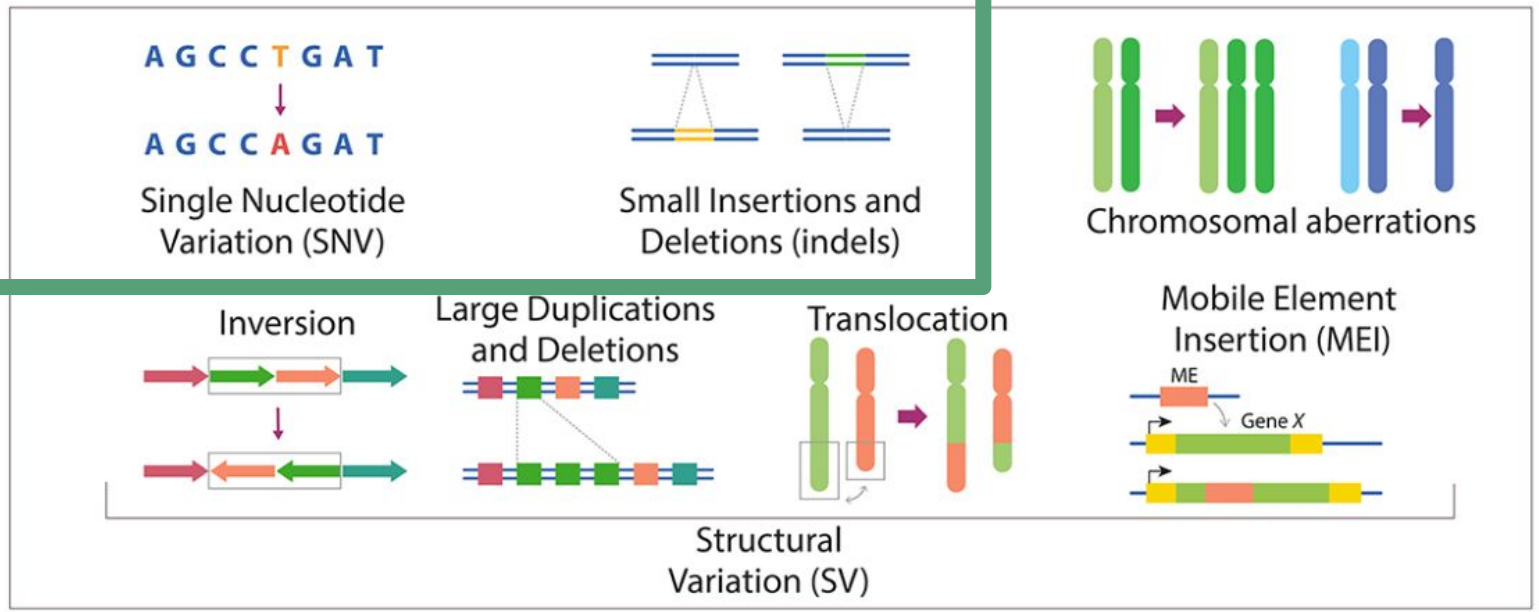
¿Qué es el perfil somático de un tumor?



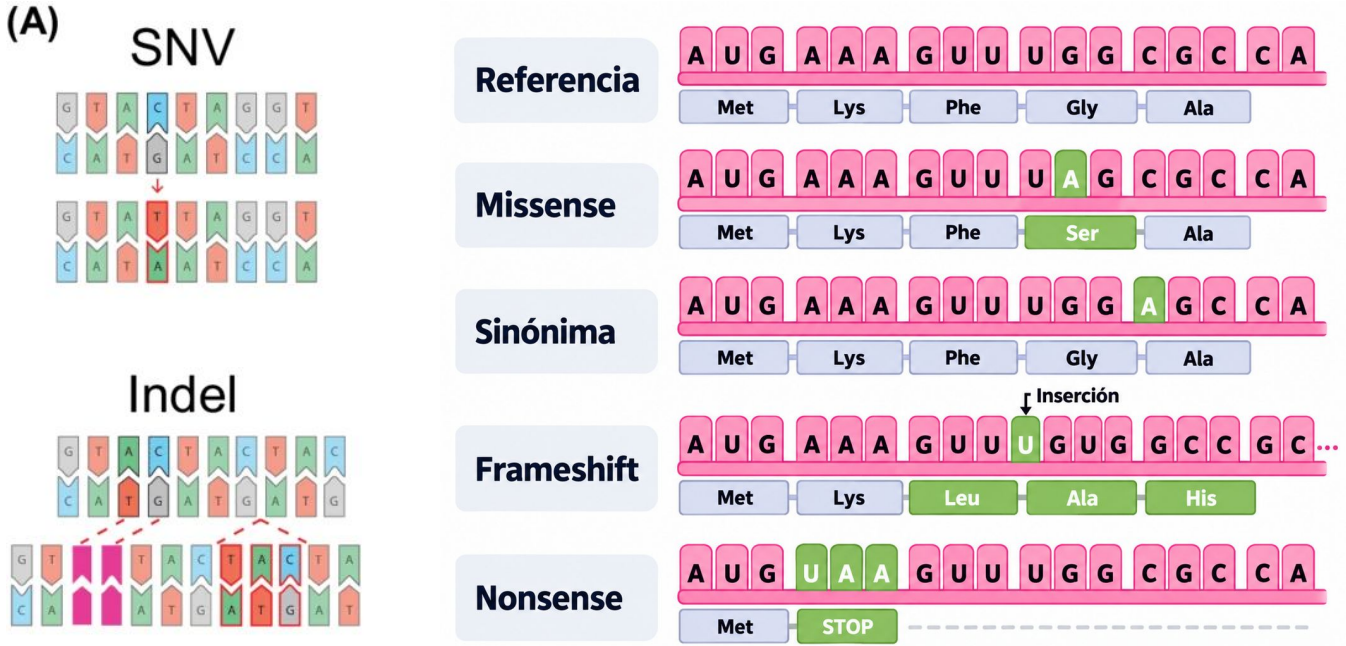
Tipos de alteraciones somáticas



Tipos de alteraciones somáticas



Variantes somáticas pequeñas: mutaciones puntuales e indels



Las **SNV** cambian una sola base; los **indels** son inserciones o deleciones pequeñas. Sus consecuencias funcionales pueden ser distintas según el contexto: **sinónima** (sin cambio de aminoácido), **missense** (cambio de aminoácido), **nonsense** (codón de stop) o **frameshift** (cambio del marco de lectura).

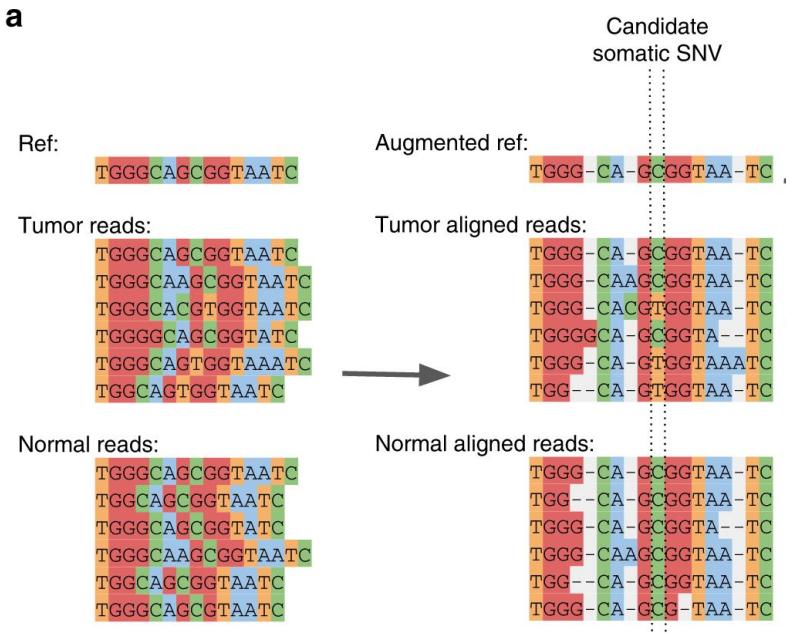
¿Cómo determinamos que una variante es *somática*?

Comparación tumor-normal

1. Secuenciamos una muestra tumoral y una muestra normal del mismo individuo.
2. Alineamos las lecturas al genoma de referencia y comparamos la evidencia en un locus.
3. Una variante candidata somática está presente en el tumor y ausente, o con señal mucho menor, en la muestra normal.

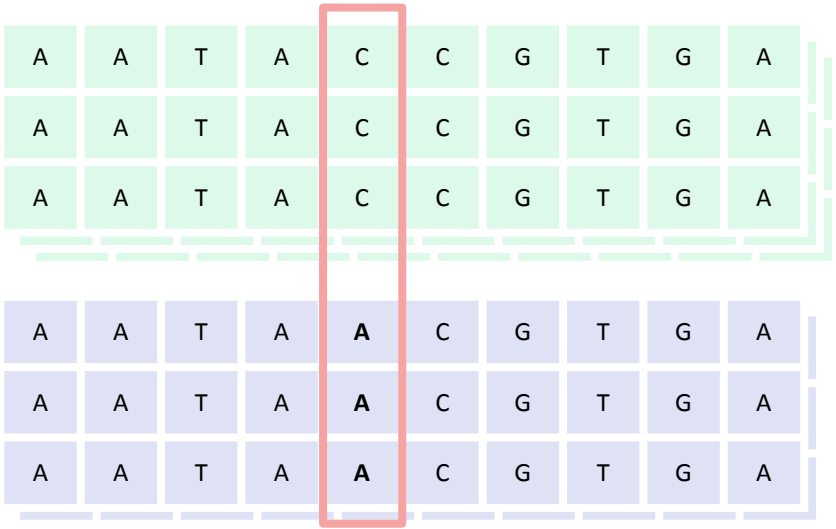
Somática = señal tumoral específica

Luego, el *variant calling* resume la evidencia y anota la variante.



Frecuencia alélica de la variante (*VAF*)

30 lecturas con alelo *referencia REF*



10 lecturas con alelo *alternativo ALT*

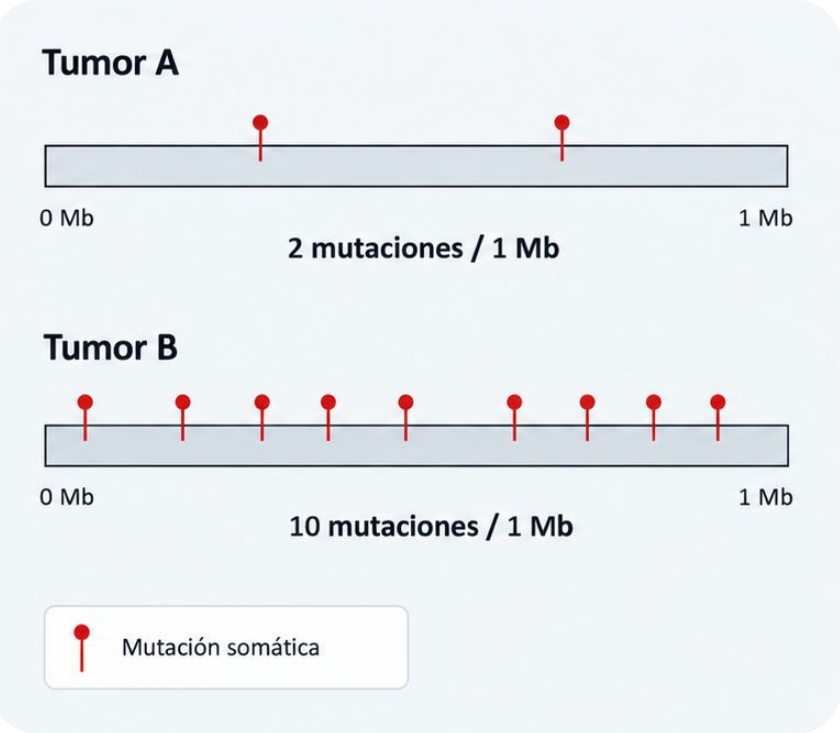
VAF (variant allele frequency) representa la proporción de lecturas que respaldan al alelo alternativo en una posición

$$\mathrm{VAF} = \frac{N_{ALT}}{N_{REF} + N_{ALT}}$$

$$\mathrm{VAF} = \frac{10}{40} = 0{,}25 = 25\ \%$$

VAF permite cuantificar la presencia de una variante y aporta información para estudiar la heterogeneidad tumoral.

Tumor mutational burden (TMB)

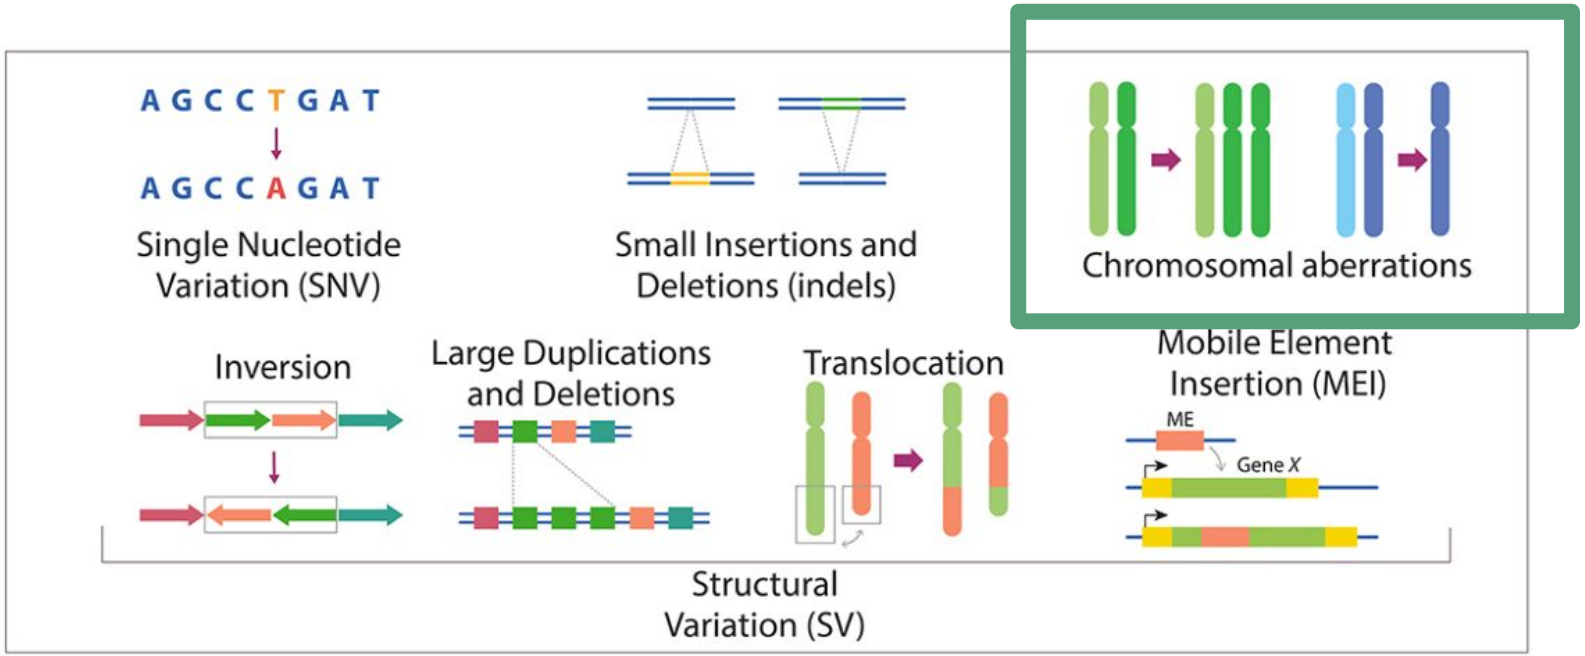


Cuantifica la carga mutacional del tumor, definido como el número de mutaciones somáticas por megabase (Mb) de región somática evaluable.

$$\text{TMB} = \frac{\text{N° de mutaciones somáticas elegibles}}{\text{Mb evaluables}}$$

Permite comparar la carga mutacional entre tumores, y depende del criterio de variables incluidas y de la región genómica evaluada.

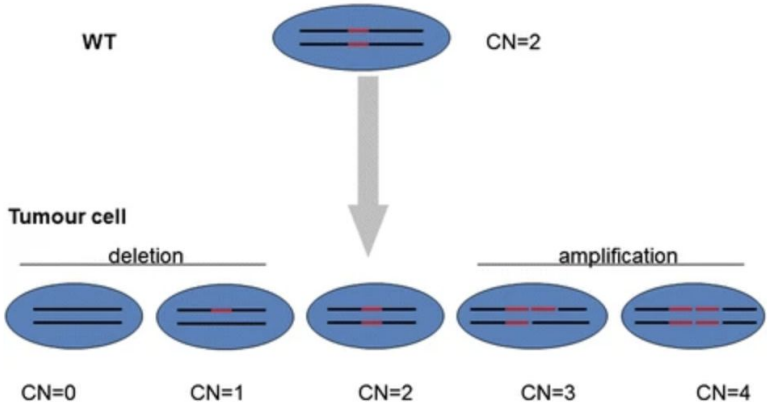
Tipos de alteraciones somáticas



Alteraciones en el número de copias: CNV

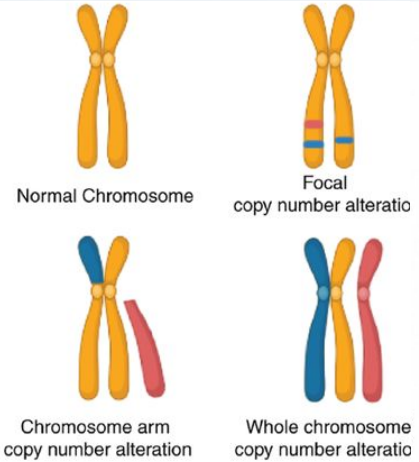
Según el número de copias

Número de copias de una región genómica



- **CN = 0:** deleción homocigota
- **CN = 1:** pérdida de una copia
- **CN = 2:** estado de referencia
- **CN ≥ 3:** ganancia / amplificación

Según la extensión genómica



- **Focal:** afecta una región genómica pequeña.
- **Brazo cromosómico:** afecta una brazo del cromosoma.
- **Cromosoma completo:** afecta todo el cromosoma.

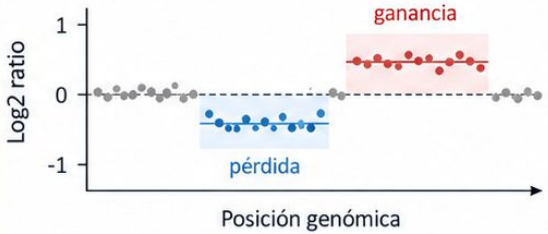
Las CNA corresponden a **ganancias** o **pérdidas de material genético** y pueden afectar desde **regiones focales hasta cromosomas completos**, modificando la dosis génica.

¿Cómo se determina un CNV?

1 Profundidad de lectura
Read depth / Log2 ratio

Compara la abundancia relativa de DNA entre tumor y normal.

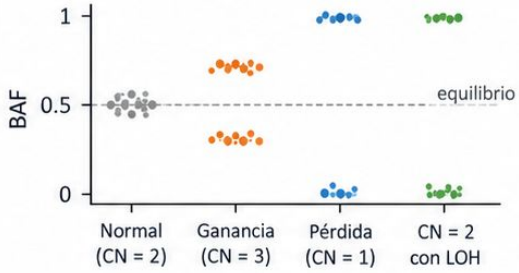
$$\log_2 R = \log_2 \left(\frac{\text{cobertura tumor}}{\text{cobertura normal}} \right)$$



2 B-allele frequency
BAF

Evalúa el balance alélico en SNP germinales heterocigotos.

$$BAF = \frac{N_B}{N_A + N_B}$$



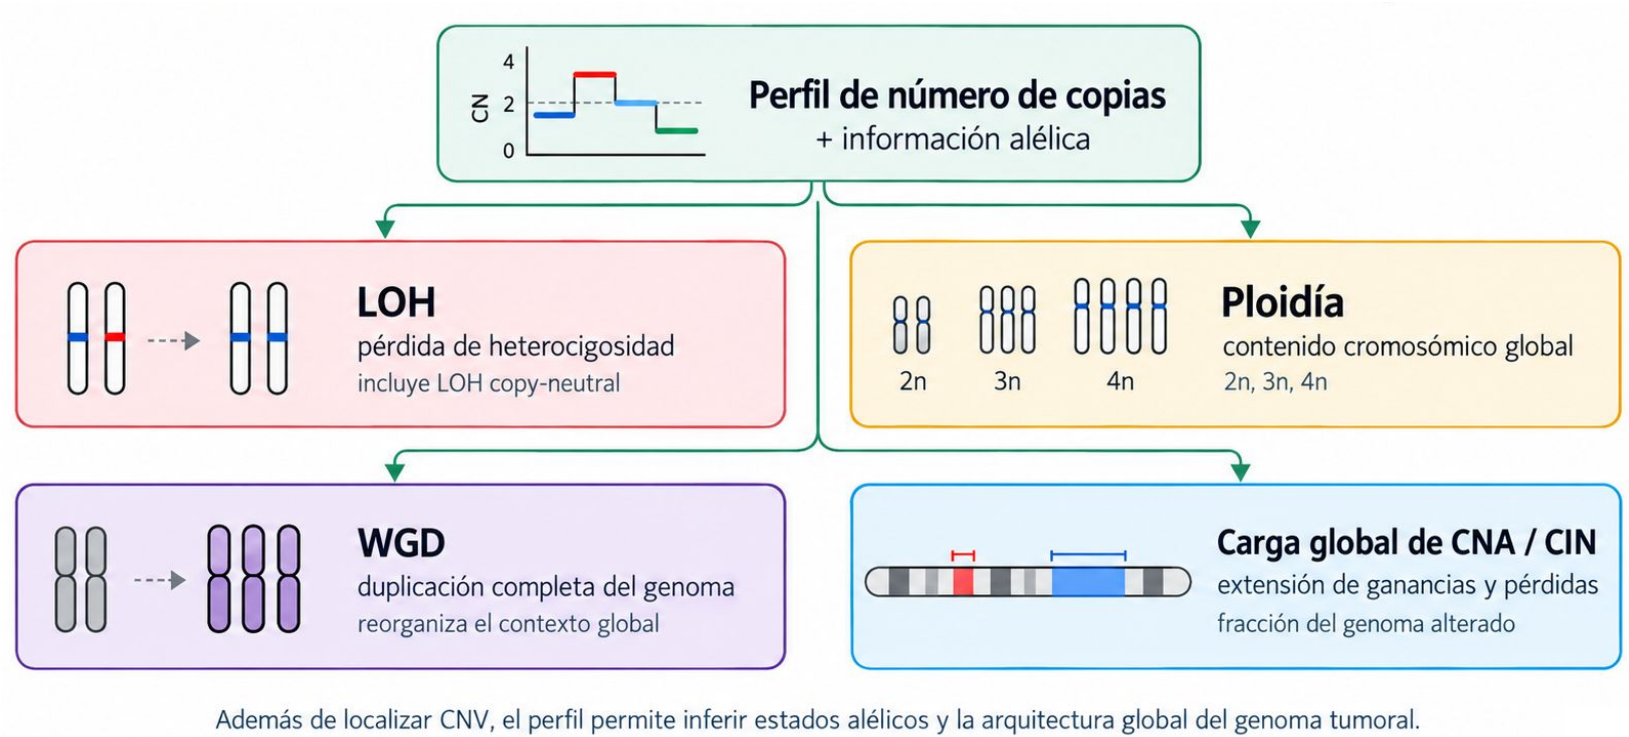
3 Inferencia de CNA

Integra ambas señales para estimar el número total y alélico de copias.

Log2R	BAF	Interpretación
~0	~0.5	CN = 2
↑	0.33 / 0.67	Ganancia (CN = 3)
↓	0 / 1	Pérdida (CN = 1)
~0	0 / 1	CN = 2 con LOH

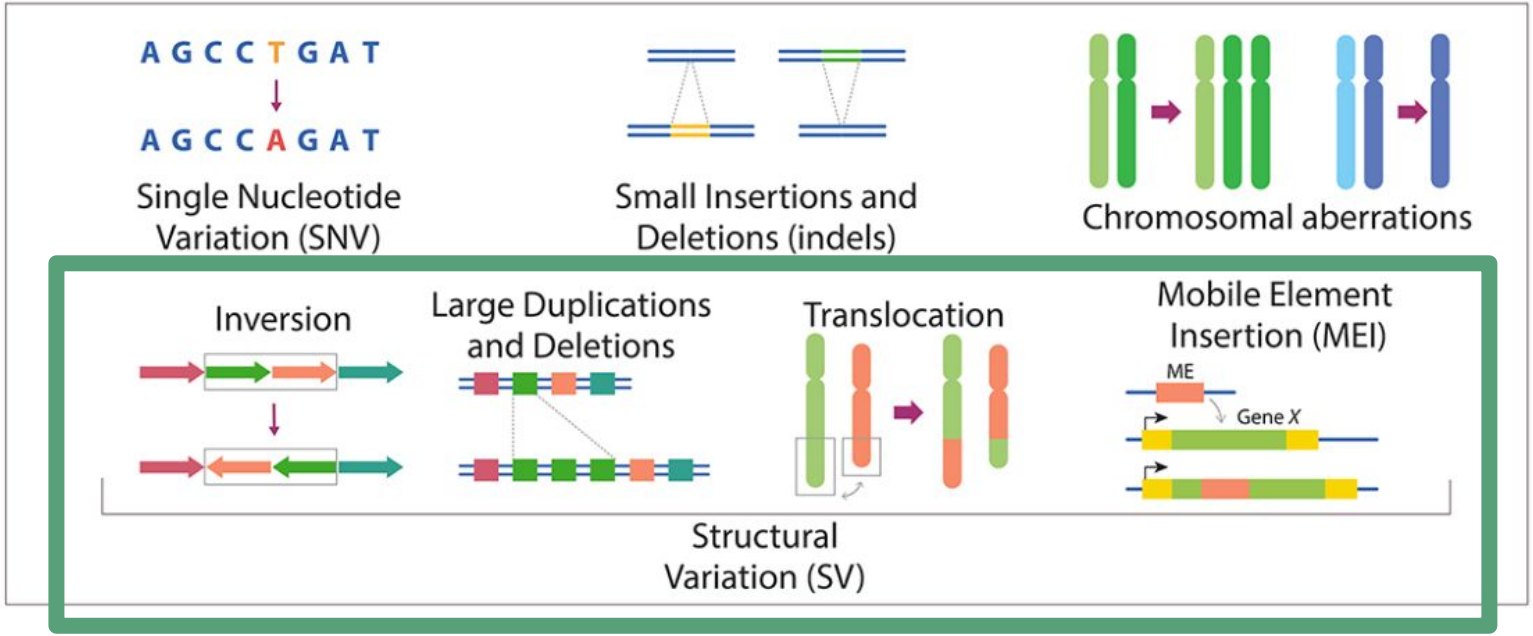
Ejemplos de herramientas: COBALT · AMBER · PURPLE

¿Qué información se obtiene a partir del análisis de CNV?

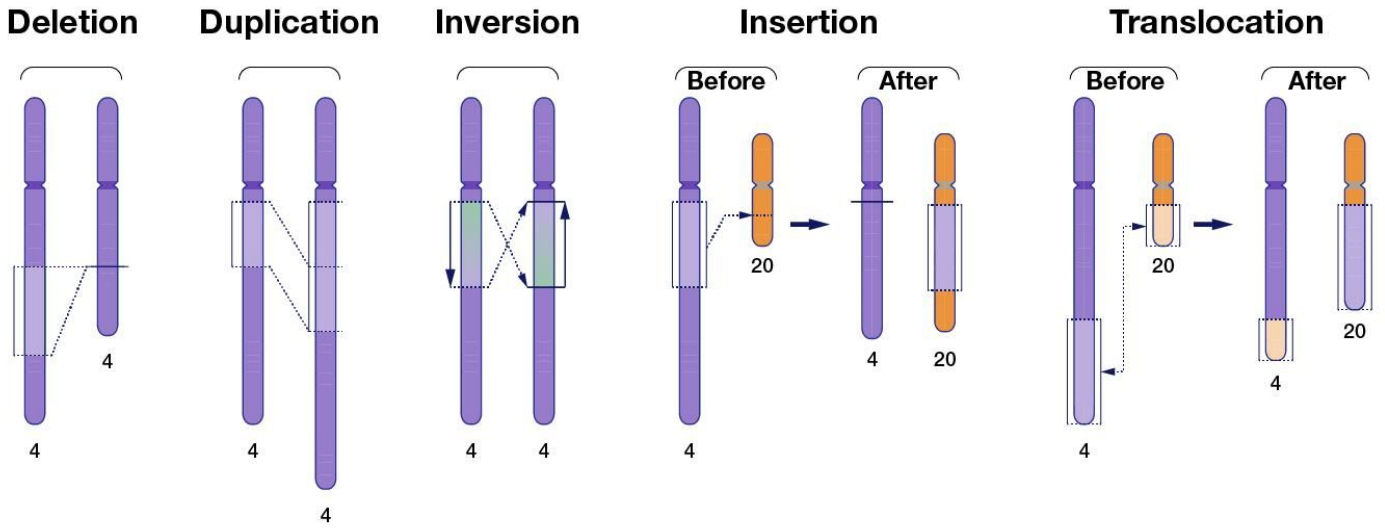


Además de localizar CNV, el perfil permite inferir estados alélicos y la arquitectura global del genoma tumoral.

Tipos de alteraciones somáticas

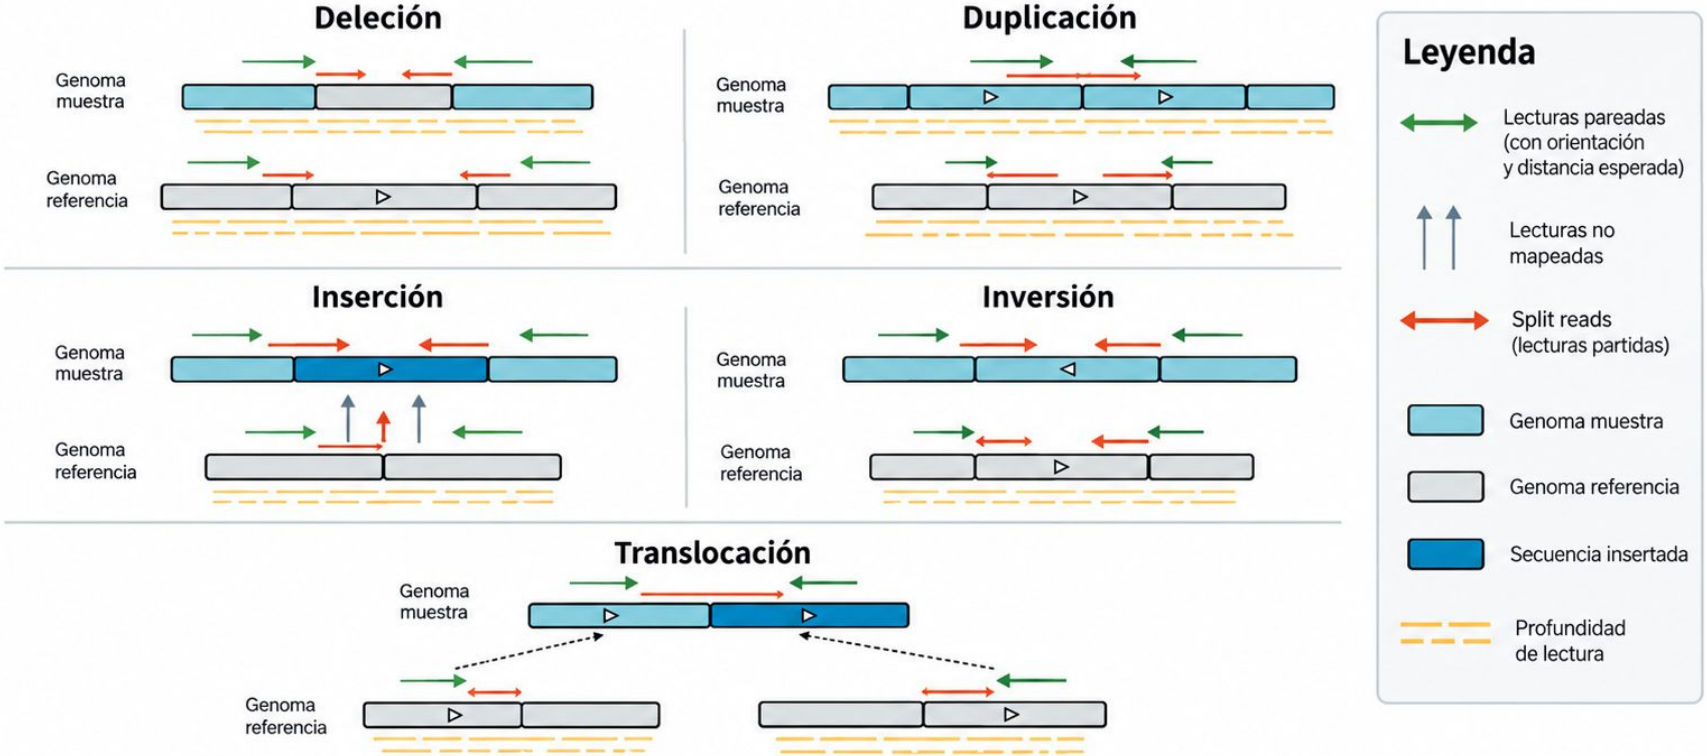


Variantes estructurales (SV)

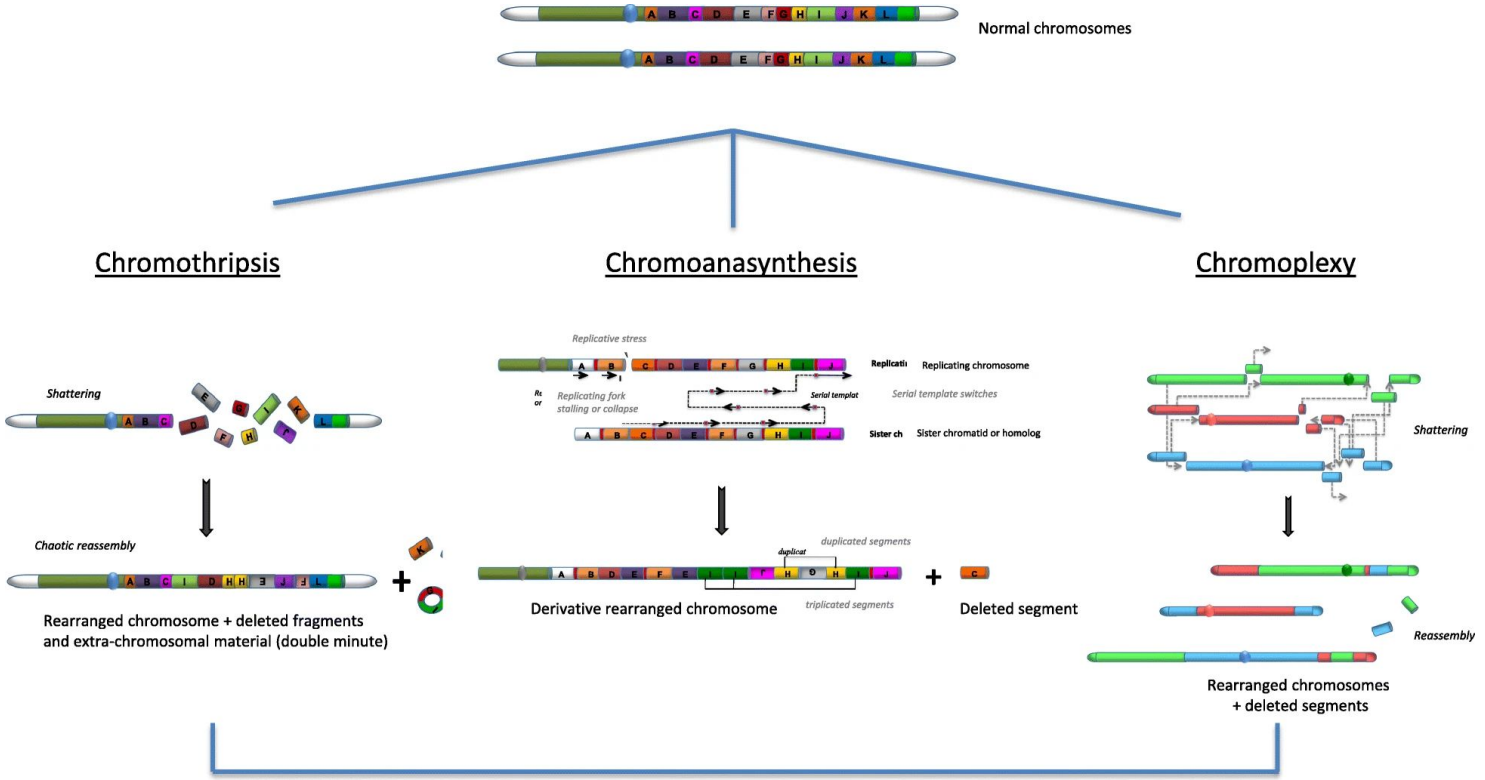


Las SV pueden alterar genes, modificar su regulación o generar fusiones génicas, incluso sin cambiar el número total de copias.

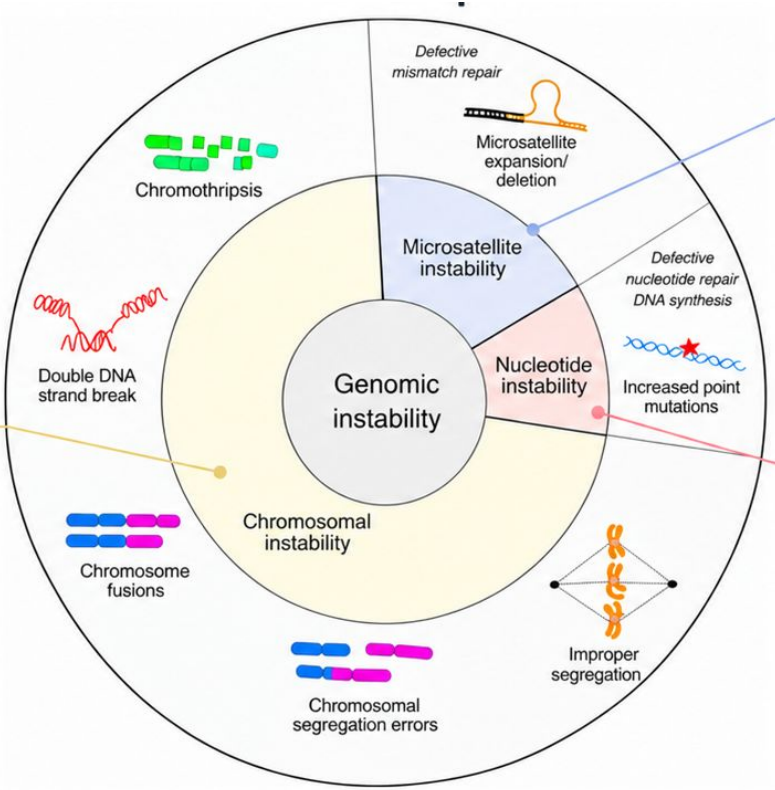
¿Cómo se detecta una variante estructural?



Eventos estructurales dan origen a reorganización genómica



Los tumores presentan distintos tipos de *inestabilidad genómica*



Inestabilidad microsatelital

Cambios en la longitud de secuencias repetitivas, usualmente asociados a deficiencia de reparación MMR.

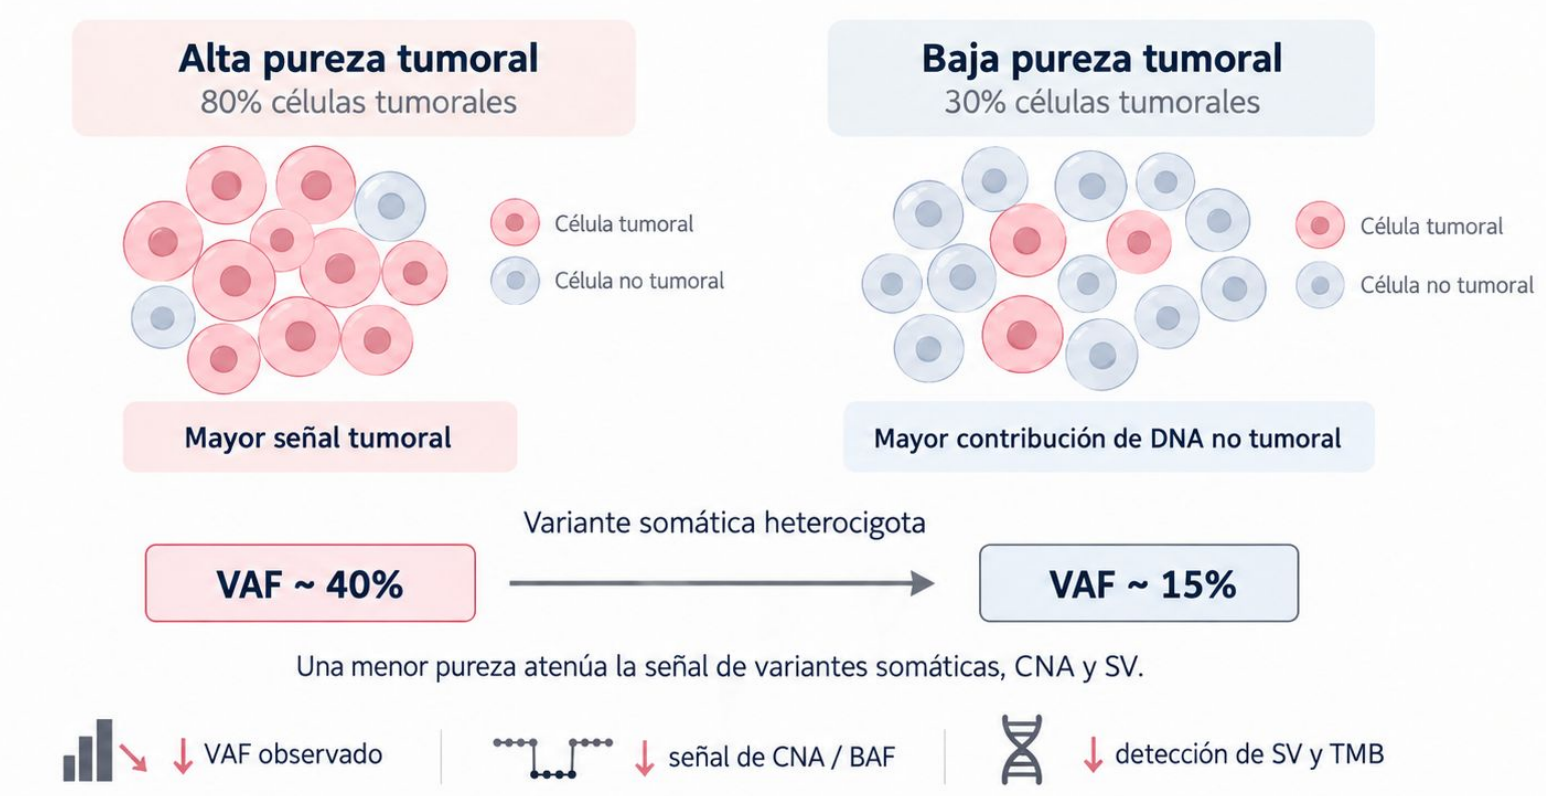
Inestabilidad cromosómica

Ganancias, pérdidas o reordenamientos de cromosomas o grandes regiones genómicas.

Inestabilidad nucleotídica

Acumulación de mutaciones puntuales y pequeños indels por errores de replicación o reparación.

La pureza tumoral afecta la caracterización genómica

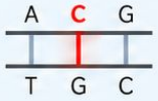


Firmas mutacionales

Patrones característicos de mutaciones asociados a procesos de daño y reparación del ADN

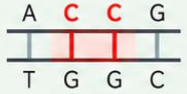
SBS
Single Base Substitutions

- Sustituciones de una base y su contexto trinucleotídico.

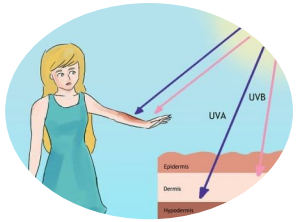


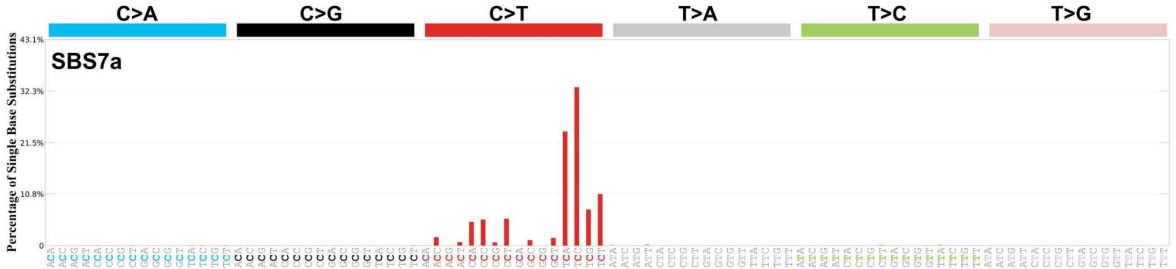
DBS
Doublet Base Substitutions

- Sustituciones de dos bases adyacentes.



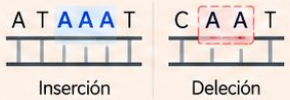
Predominio de sustituciones C>T en contexto dipirimidínicos





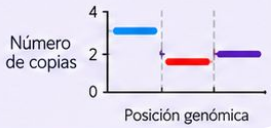
ID
Insertions and Deletions

- Inserciones y deleciones pequeñas según longitud y contexto.



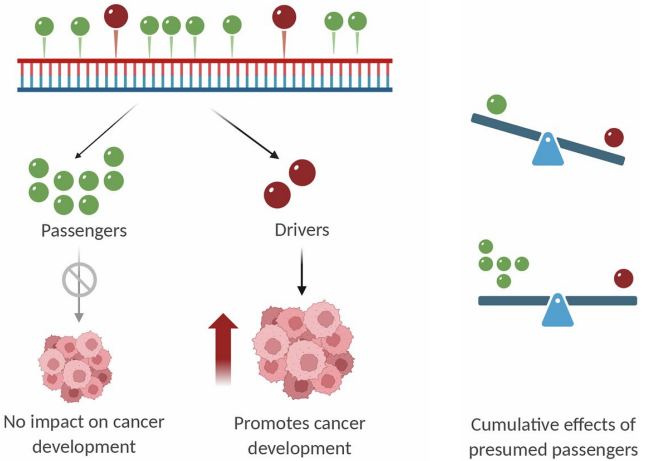
CN
Copy Number

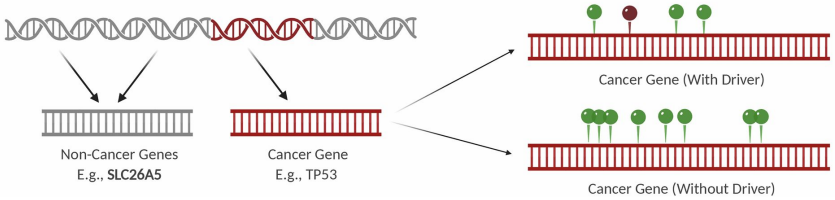
- Patrones de alteraciones del número de copias.

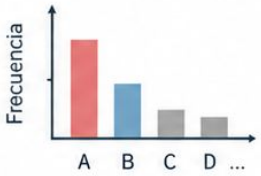


Las mutaciones pueden ser *driver* o pasajeras

¿Cómo se identifica una mutación driver?



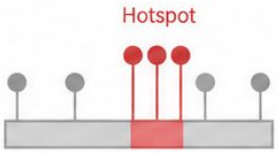




1 Recurrencia

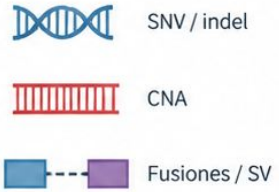
Genes con más alteraciones de las esperadas según la tasa mutacional de fondo.

Ejemplos: MutSigCV, dNdScv



2 Patrones de alteración

Enriquecimiento de mutaciones en posiciones específicas (hotspots) o de ciertos tipos de alteraciones (p. ej. truncantes), indicando selección positiva.

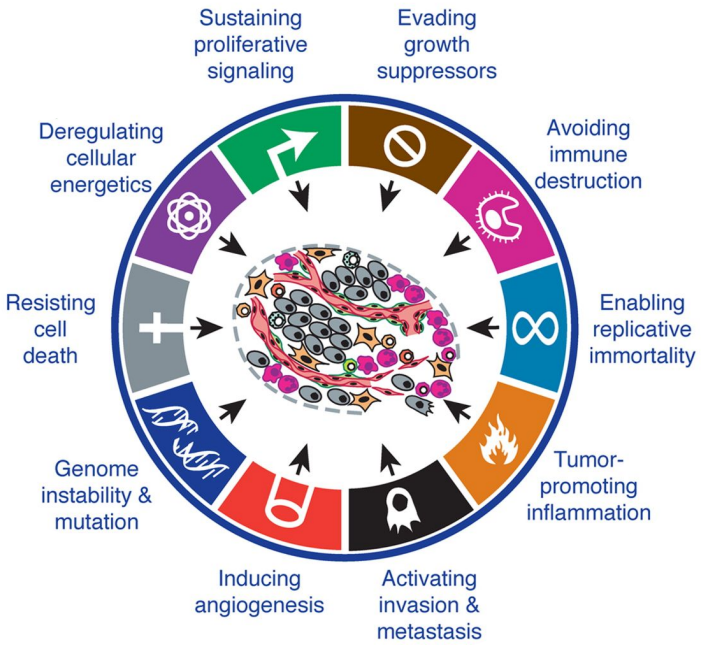


3 Evidencia funcional

Consecuencia molecular de la alteración y evidencia previa (experimental o clínica).

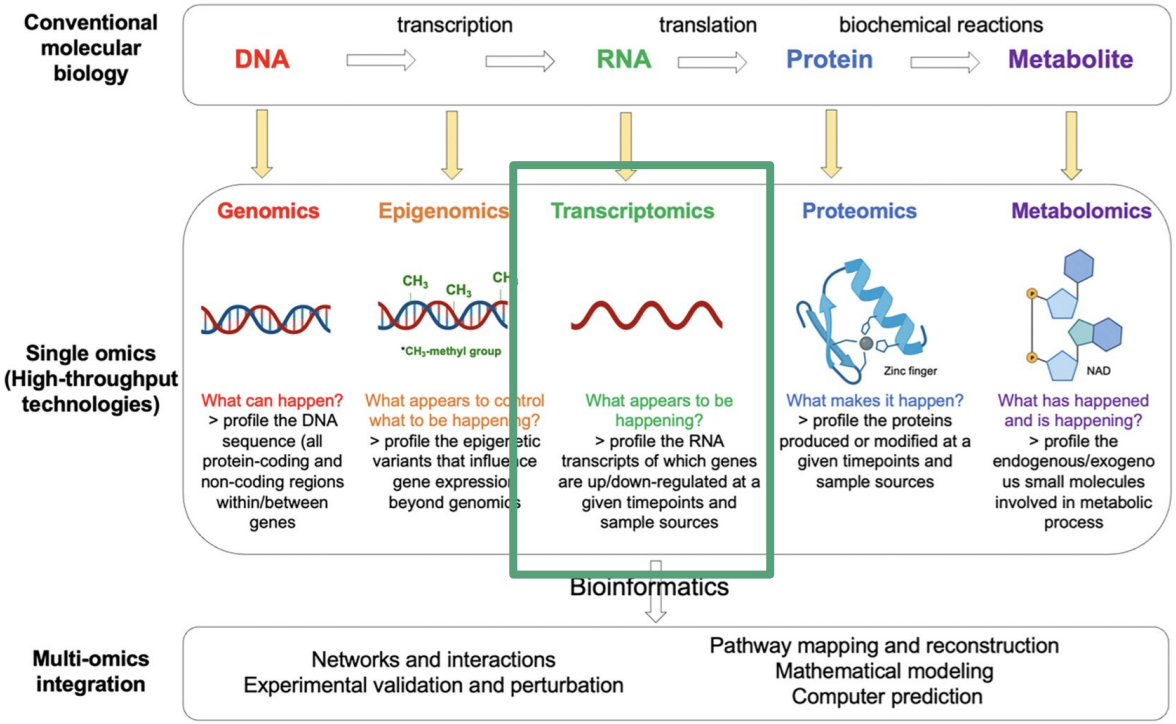
Ejemplos: anotación funcional, COSMIC, Cancer Gene Census

Las alteraciones convergen en los *hallmark del cáncer*





El cáncer desde múltiples perspectivas moleculares



Enfoque multi-ómico

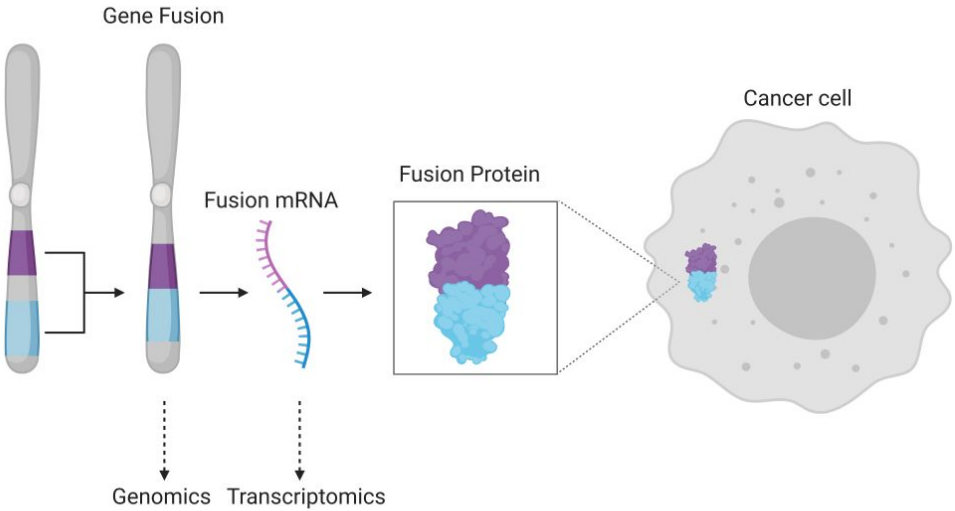
- Integra distintas capas moleculares del mismo tumor.
- Relaciona alteraciones del ADN con expresión, regulación y fenotipo.
- Permite una visión más completa que una sola ómica.

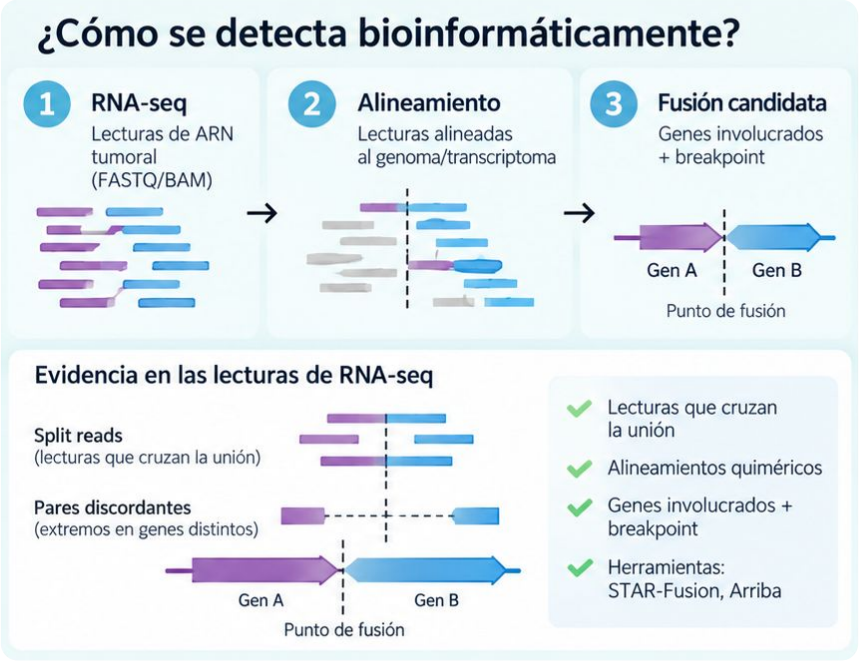
Ejemplos de asociación

- Mutaciones / CNA → cambios de expresión génica
- Metilación → silenciamiento de genes
- Firmas mutacionales → procesos biológicos activos
- Perfiles moleculares + clínica → subtipos y pronóstico

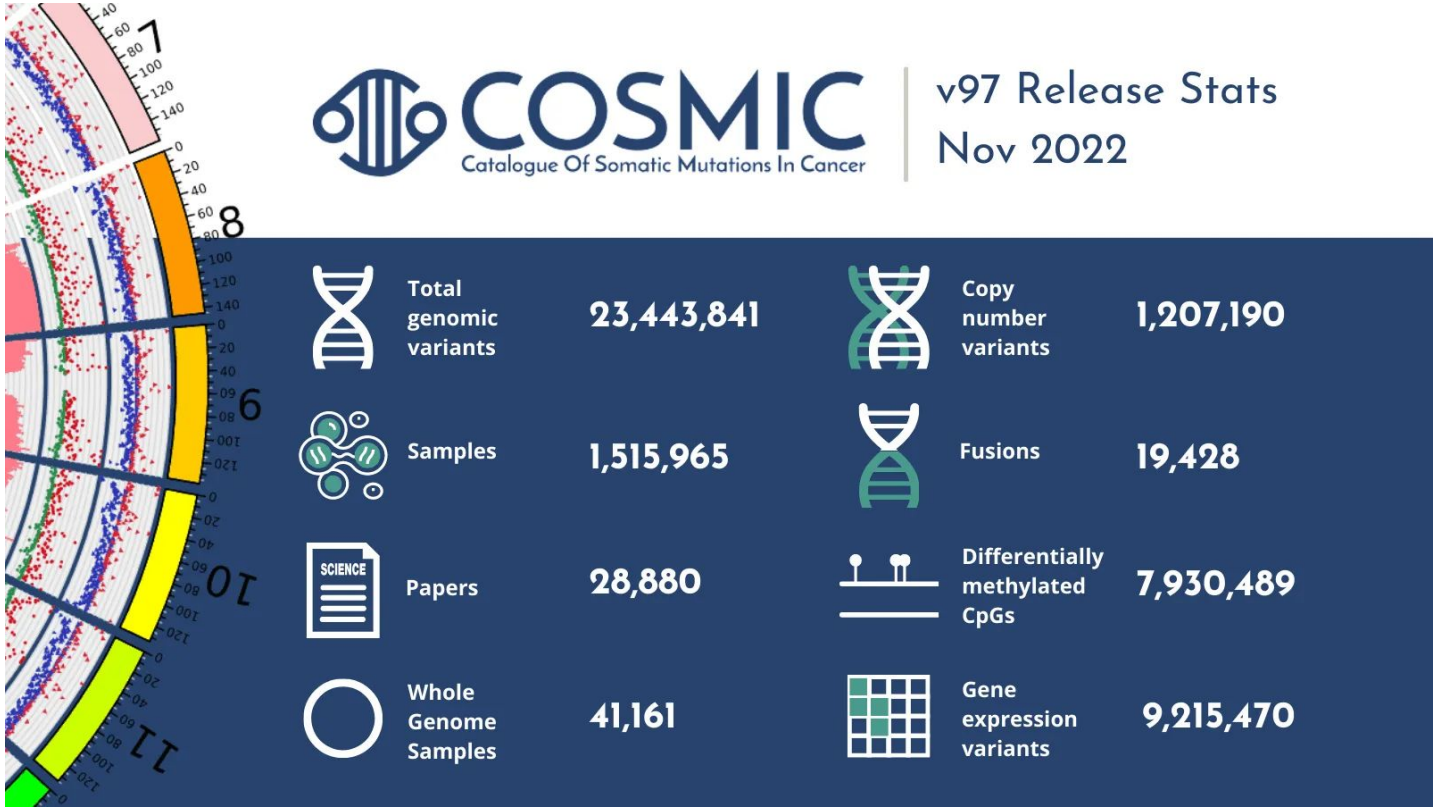
La integración multi-ómica ayuda a conectar genotipo, regulación y fenotipo tumoral.

Aproximando alteraciones estructurales con transcriptómica detectando fusiones de genes





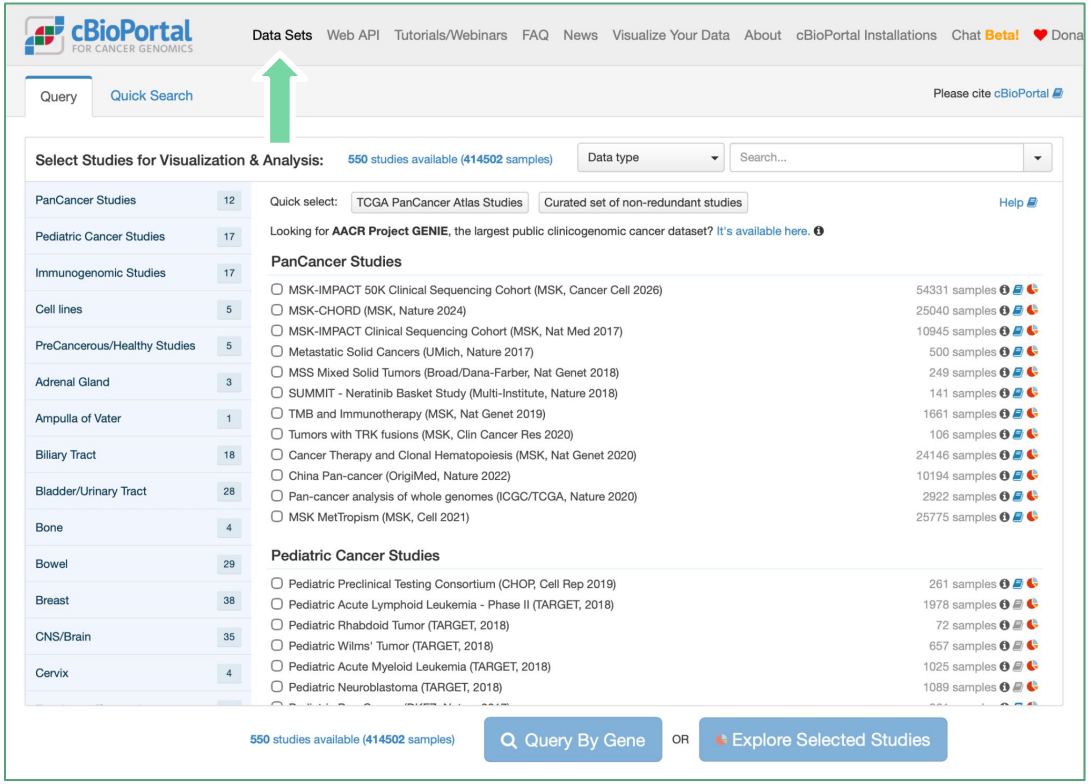
COSMIC

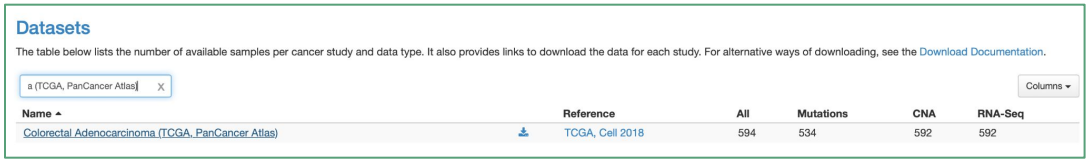

COSMIC
Catalogue Of Somatic Mutations In Cancer
v97 Release Stats
Nov 2022
Total genomic variants
23,443,841
Copy number variants
1,207,190
Samples
1,515,965
Fusions
19,428
SCIENCE
Papers
28,880
Differentially methylated CpGs
7,930,489
Whole Genome Samples
41,161
Gene expression variants
9,215,470

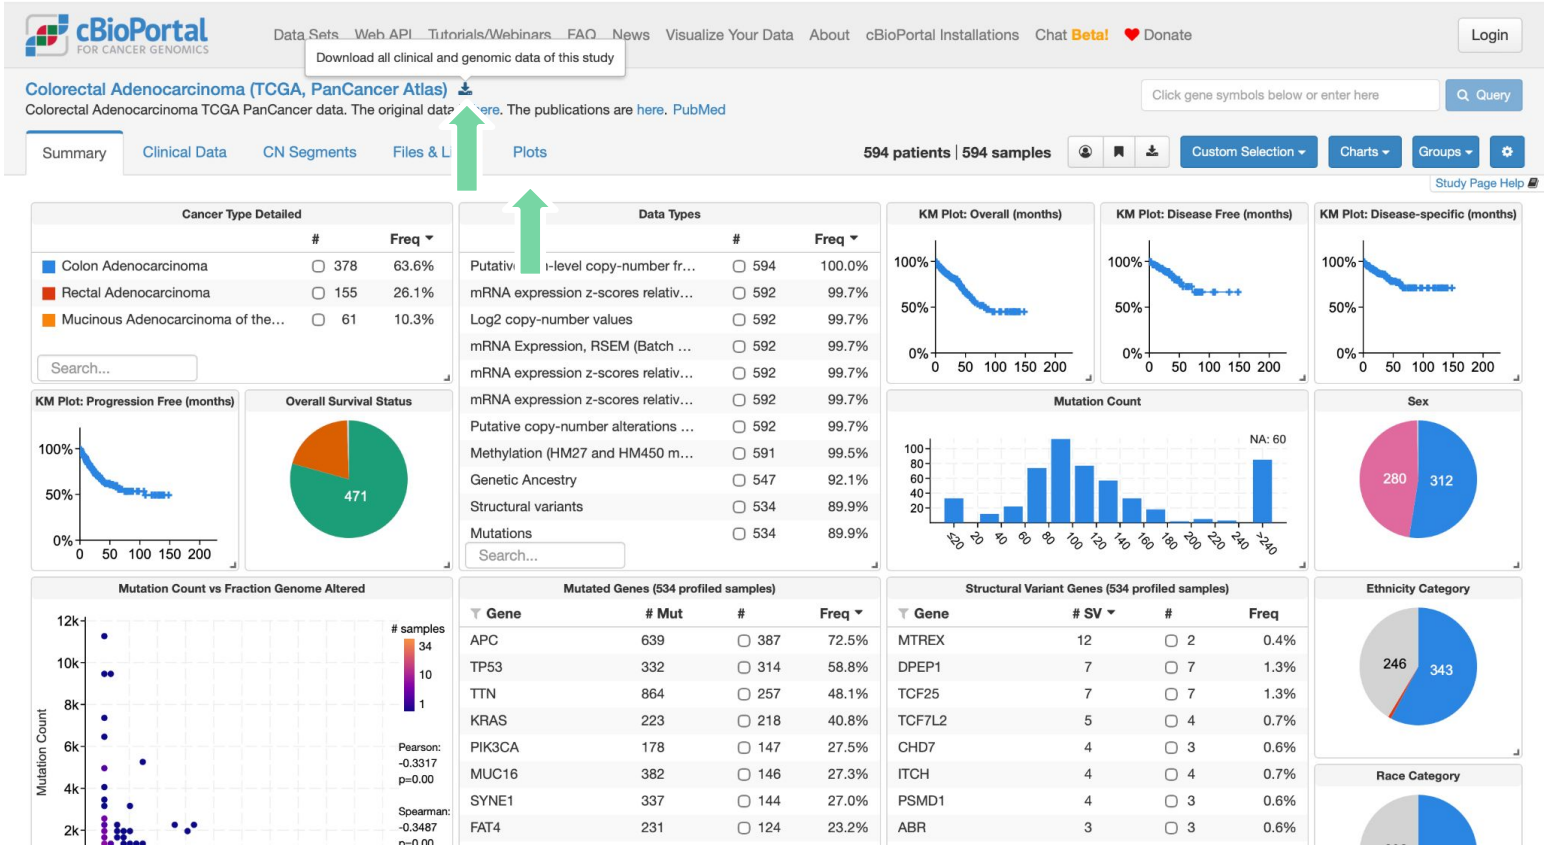
Taller práctico I

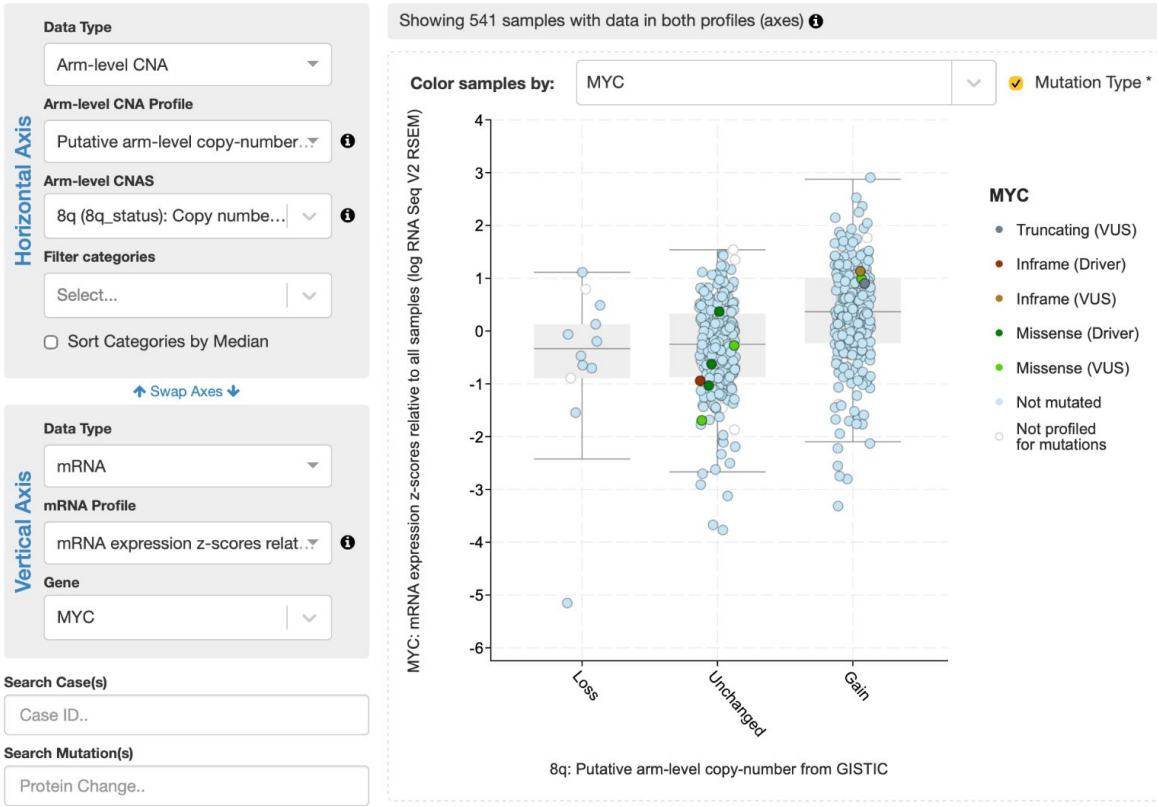
Revisión y análisis de mutaciones puntuales en adenocarcinoma colorrectal

1. Entrar a cBioPortal y descargar el dataset Colorectal Adenocarcinoma (TCGA, PanCancer Atlas).
2. Realizar los siguientes gráficos dentro de la misma interfaz.
    a. Revisar mRNA vs CNA de MYC (8q24). La vía MYC se mantiene activa cuando APC está mutado. ¿Hay una relación?
    b. MSI en cáncer colorrectal se relaciona con la metilación del gen MLH1, revisar subtipo de cáncer vs metilación MLH1.

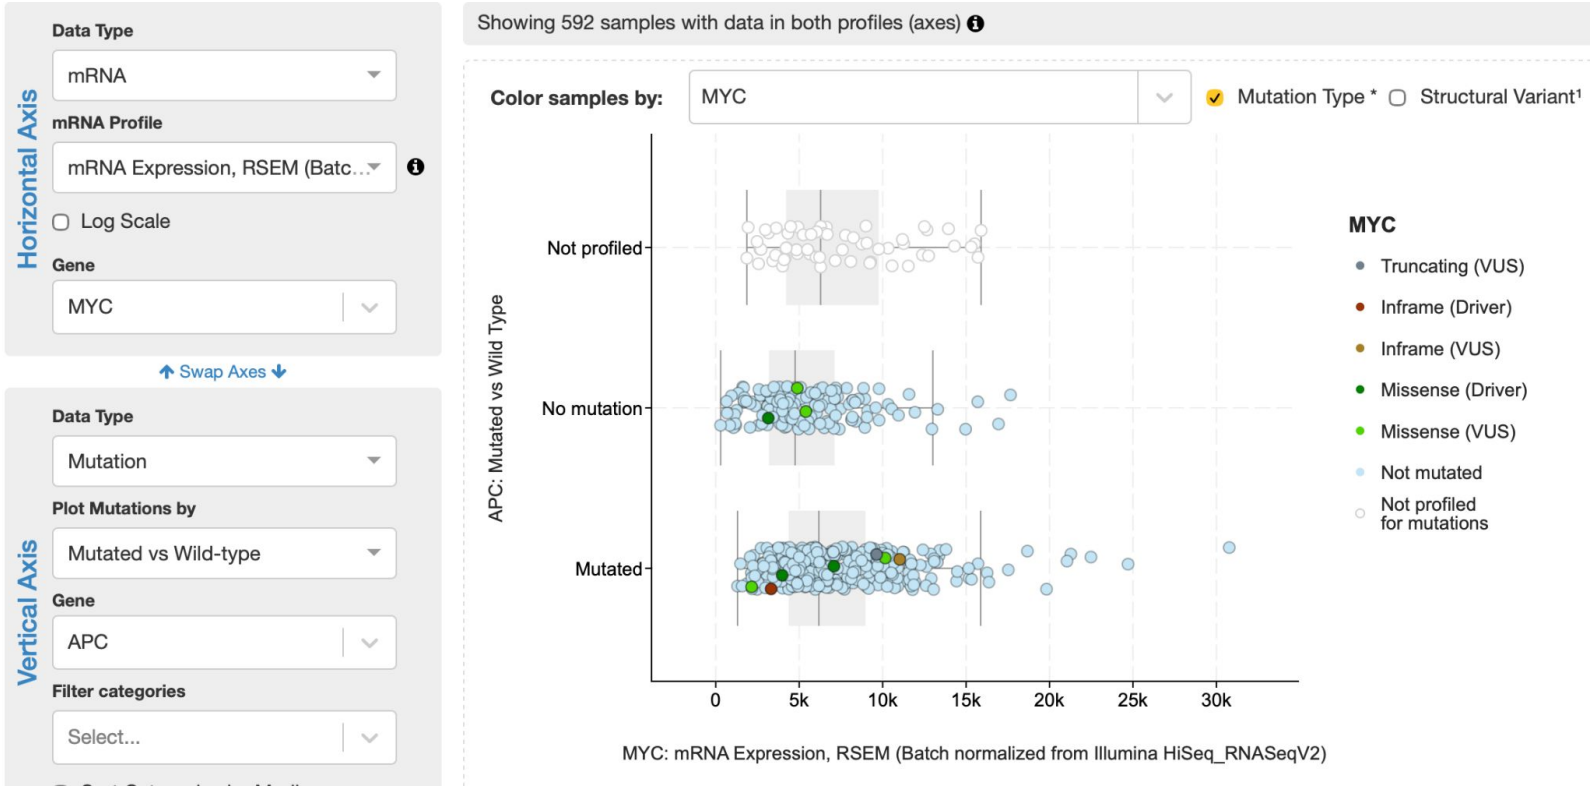

cBioPortal
FOR CANCER GENOMICS
Data Sets
Web API
Tutorials/Webinars
FAQ
News
Visualize Your Data
About
cBioPortal Installations
Chat Beta!
Query
Quick Search
Please cite cBioPortal
Select Studies for Visualization & Analysis:
550 studies available (414502 samples)
Data type
Search...
PanCancer Studies 12
Pediatric Cancer Studies 17
Immunogenomic Studies 17
Cell lines 5
PreCancerous/Healthy Studies 5
Adrenal Gland 3
Ampulla of Vater 1
Biliary Tract 18
Bladder/Urinary Tract 28
Bone 4
Bowel 29
Breast 38
CNS/Brain 35
Cervix 4
Quick select:
TCGA PanCancer Atlas Studies
Curated set of non-redundant studies
Help
Looking for AACR Project GENIE, the largest public clinicogenomic cancer dataset? It's available here.
PanCancer Studies
MSK-IMPACT 50K Clinical Sequencing Cohort (MSK, Cancer Cell 2026) 54331 samples
MSK-CHORD (MSK, Nature 2024) 25040 samples
MSK-IMPACT Clinical Sequencing Cohort (MSK, Nat Med 2017) 10945 samples
Metastatic Solid Cancers (UMich, Nature 2017) 500 samples
MSS Mixed Solid Tumors (Broad/Dana-Farber, Nat Genet 2018) 249 samples
SUMMIT - Neratinib Basket Study (Multi-Institute, Nature 2018) 141 samples
TMB and Immunotherapy (MSK, Nat Genet 2019) 1661 samples
Tumors with TRK fusions (MSK, Clin Cancer Res 2020) 106 samples
Cancer Therapy and Clonal Hematopoiesis (MSK, Nat Genet 2020) 24146 samples
China Pan-cancer (OrigiMed, Nature 2022) 10194 samples
Pan-cancer analysis of whole genomes (ICGC/TCGA, Nature 2020) 2922 samples
MSK MetTropism (MSK, Cell 2021) 25775 samples
Pediatric Cancer Studies
Pediatric Preclinical Testing Consortium (CHOP, Cell Rep 2019) 261 samples
Pediatric Acute Lymphoid Leukemia - Phase II (TARGET, 2018) 1978 samples
Pediatric Rhabdoid Tumor (TARGET, 2018) 72 samples
Pediatric Wilms' Tumor (TARGET, 2018) 657 samples
Pediatric Acute Myeloid Leukemia (TARGET, 2018) 1025 samples
Pediatric Neuroblastoma (TARGET, 2018) 1089 samples
550 studies available (414502 samples)
Query By Gene
OR
Explore Selected Studies


Datasets
The table below lists the number of available samples per cancer study and data type. It also provides links to download the data for each study. For alternative ways of downloading, see the Download Documentation.
a (TCGA, PanCancer Atlas)
Columns
Name
Reference
All
Mutations
CNA
RNA-Seq
Colorectal Adenocarcinoma (TCGA, PanCancer Atlas)
TCGA, Cell 2018
594
534
592
592

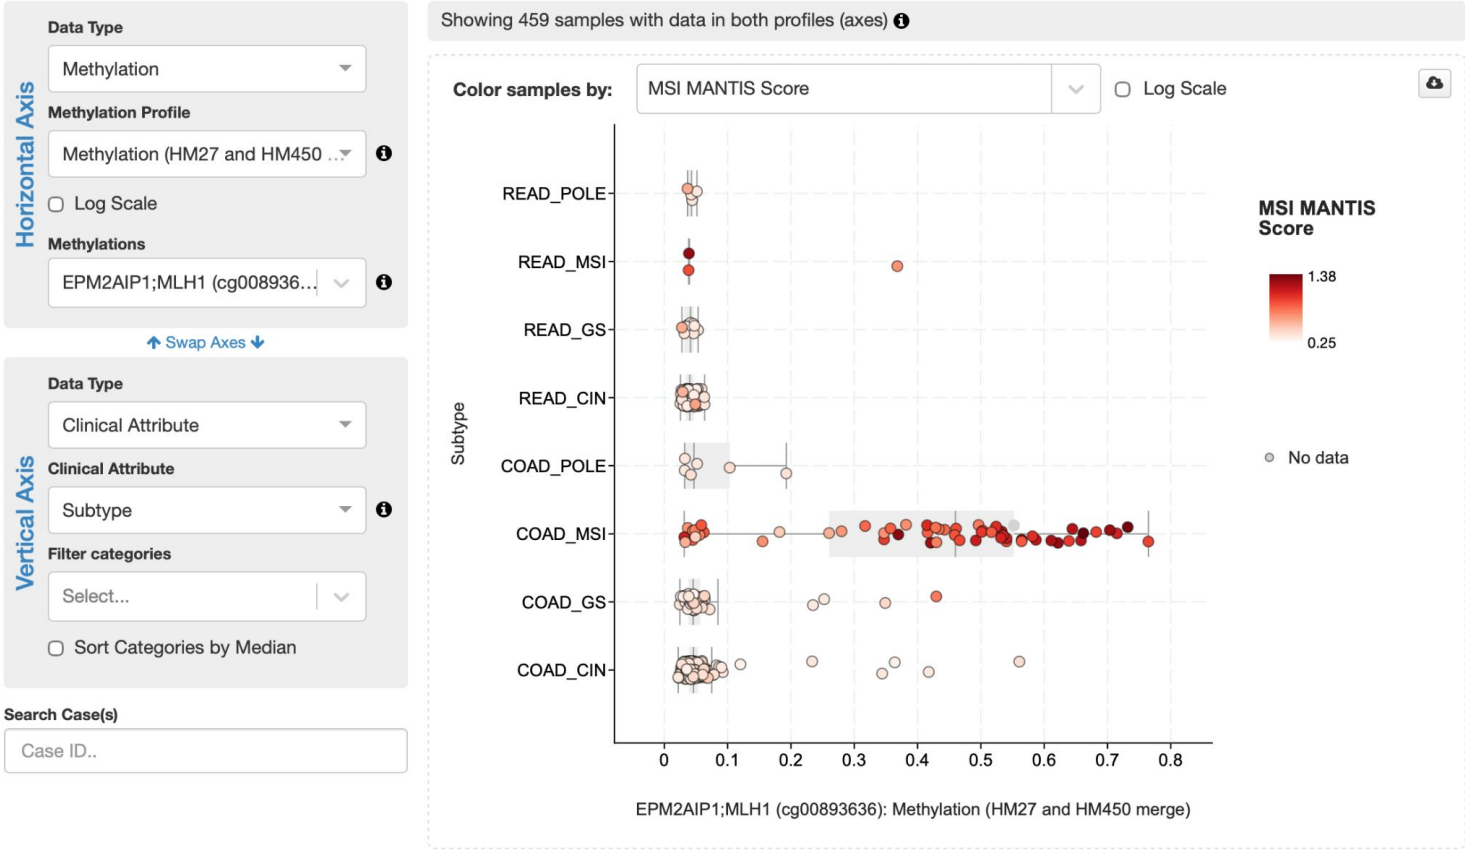

cBioPortal FOR CANCER GENOMICS
Data Sets Web API Tutorials/Webinars FAQ News Visualize Your Data About cBioPortal Installations Chat Beta! Donate
Login
Download all clinical and genomic data of this study
Colorectal Adenocarcinoma (TCGA, PanCancer Atlas)
Colorectal Adenocarcinoma TCGA PanCancer data. The original data here. The publications are here. PubMed
Click gene symbols below or enter here
Query
Summary Clinical Data CN Segments Files & L Plots
594 patients | 594 samples
Custom Selection Charts Groups
Study Page Help
Cancer Type Detailed
Freq
Colon Adenocarcinoma 378 63.6%
Rectal Adenocarcinoma 155 26.1%
Mucinous Adenocarcinoma of the… 61 10.3%
Search...
Data Types
Freq
Putativ -level copy-number fr… 594 100.0%
mRNA expression z-scores relativ… 592 99.7%
Log2 copy-number values 592 99.7%
mRNA Expression, RSEM (Batch … 592 99.7%
mRNA expression z-scores relativ… 592 99.7%
mRNA expression z-scores relativ… 592 99.7%
Putative copy-number alterations … 592 99.7%
Methylation (HM27 and HM450 m… 591 99.5%
Genetic Ancestry 547 92.1%
Structural variants 534 89.9%
Mutations 534 89.9%
Search...
KM Plot: Overall (months)
KM Plot: Disease Free (months)
KM Plot: Disease-specific (months)
KM Plot: Progression Free (months)
Overall Survival Status
471
Mutation Count
NA: 60
Sex
280
312
Mutation Count vs Fraction Genome Altered
Mutation Count
samples
Pearson: -0.3317 p=0.00
Spearman: -0.3487
Mutated Genes (534 profiled samples)
Gene # Mut # Freq
APC 639 387 72.5%
TP53 332 314 58.8%
TTN 864 257 48.1%
KRAS 223 218 40.8%
PIK3CA 178 147 27.5%
MUC16 382 146 27.3%
SYNE1 337 144 27.0%
FAT4 231 124 23.2%
Structural Variant Genes (534 profiled samples)
Gene # SV # Freq
MTREX 12 2 0.4%
DPEP1 7 7 1.3%
TCF25 7 7 1.3%
TCF7L2 5 4 0.7%
CHD7 4 3 0.6%
ITCH 4 4 0.7%
PSMD1 4 3 0.6%
ABR 3 3 0.6%
Ethnicity Category
246
343
Race Category



La alta expresión de MYC se relaciona con el aumento en su número de copias



Las mutaciones en APC aumentan la expresión de MYC sin mutaciones, manteniendo activa su función



Adenocarcinoma de colon presenta mayor inestabilidad MSI, relacionado con mayor metilación de MLH1.

Taller práctico II

Revisión y análisis de mutaciones puntuales en adenocarcinoma colorrectal

1. Utilizar *maftools* en R para analizar la frecuencia de mutaciones en las cohortes.
    a. ¿Cuál es el perfil mutacional general de la cohorte?
    b. ¿Qué genes están recurrentemente mutados?
    c. ¿Las mutaciones se distribuyen uniformemente a lo largo de un gen? Revisar las mutaciones en APC y KRAS

https://github.com/noemigomezr/cancer_genomics_class

```
git clone https://github.com/noemigomezr/cancer_genomics_class.git
cd cancer_genomics_class/practico/files
unzip data_mutations.txt.zip
```

```r
install.packages("BiocManager")

install.packages("tidyverse")
BiocManager::install("maftools")

library(tidyverse)
library(maftools)
```

```r
data_mutations <- read_tsv("../files/data_mutations.txt", show_col_types = FALSE)
data_clinical_sample <- read_tsv("../files/data_clinical_sample.txt",
                                 comment = "#", show_col_types = FALSE)
data_clinical_patient <- read_tsv("../files/data_clinical_patient.txt",
                                  comment = "#", show_col_types = FALSE)
```

```r
muestras_evaluadas <- data_mutations %>%
  distinct(Tumor_Sample_Barcode)

metadata <- data_clinical_sample %>%
  mutate(Tumor_Sample_Barcode = SAMPLE_ID) %>%
  semi_join(muestras_evaluadas, by = "Tumor_Sample_Barcode") %>%
  left_join(data_clinical_patient, by = "PATIENT_ID")
```

MAF: Mutation Annotation Format

	Hugo_Symbol	Entrez_Gene_Id	Center	NCBI_Build	Chromosome	Start_Position	End_Position	Strand
1	DMBT1	1755	.	GRCh37	10	124399948	124399948	+
2	C10orf90	118611	.	GRCh37	10	128193330	128193330	+
3	WDFY4	57705	.	GRCh37	10	49997997	49997997	+
4	PRKCQ	5588	.	GRCh37	10	6533674	6533674	+
5	DYNC2H1	79659	.	GRCh37	11	103153768	103153768	+

	Consequence	Variant_Classification	Variant_Type	Reference_Allele
1	synonymous_variant	Silent	SNP	T
2	missense_variant	Missense_Mutation	SNP	C
3	missense_variant	Missense_Mutation	SNP	C
4	missense_variant	Missense_Mutation	SNP	C
5	missense_variant	Missense_Mutation	SNP	C



```
data_wgd <- read_tsv("../files/wgd_tcga.tsv", show_col_types = FALSE) %>%
  select(Tumor_Sample_Barcode = array, WGD = `Genome doublings`, purity) %>%
  mutate(WGD = WGD > 0)

metadata <- metadata %>%
  left_join(data_wgd, by = "Tumor_Sample_Barcode")
```

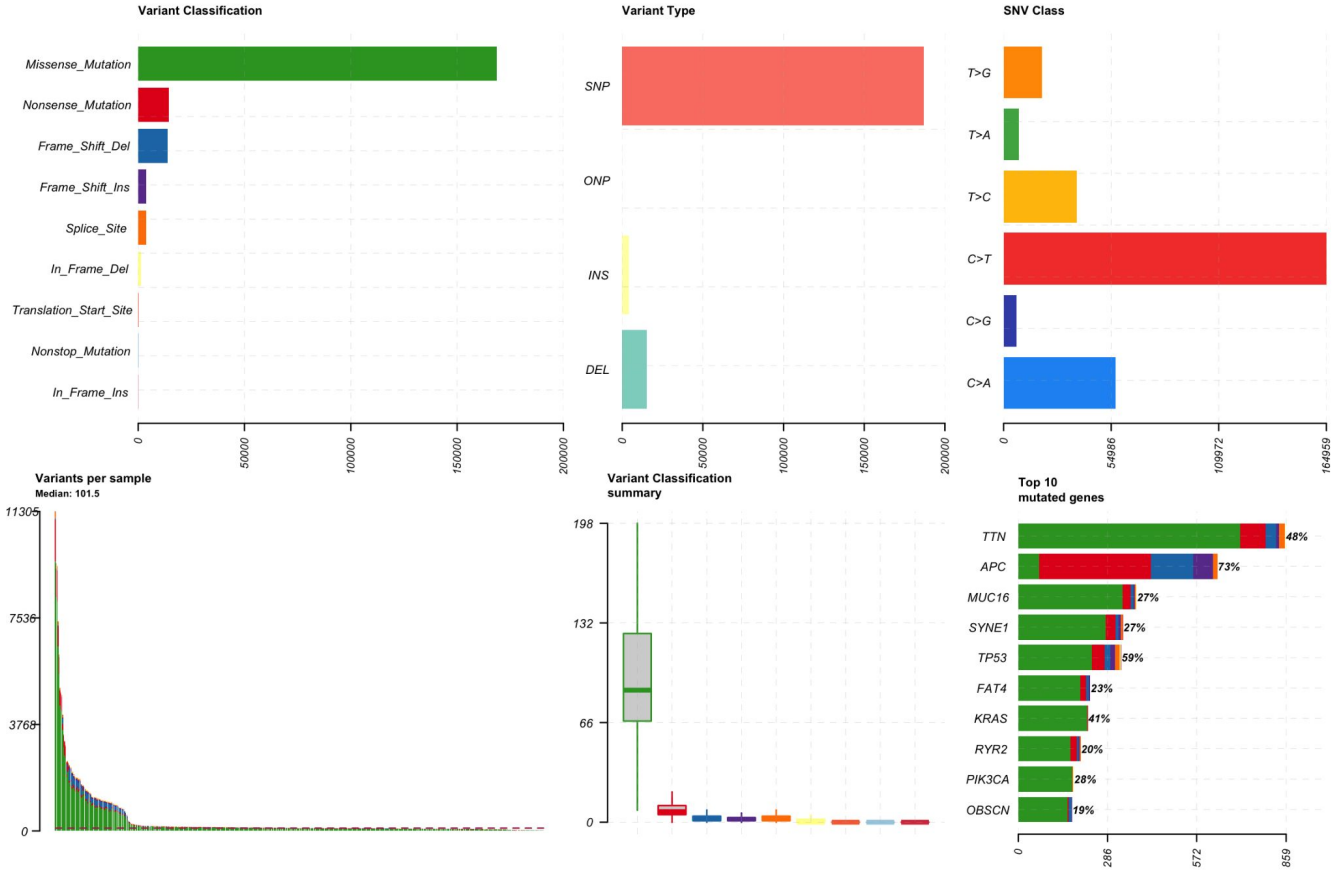
```
table(data_mutations$FILTER, useNA = "ifany")

data_mutations <- data_mutations %>%
  filter(FILTER == "PASS",
         Chromosome %in% as.character(1:22))
```

```
metadata <- metadata %>%
  mutate(SUBTYPE = str_remove(SUBTYPE, "^(COAD|READ)_"))
maf <- read.maf(maf = data_mutations, clinicalData = metadata)
```

¿Cuál es el perfil mutacional general de la cohorte?

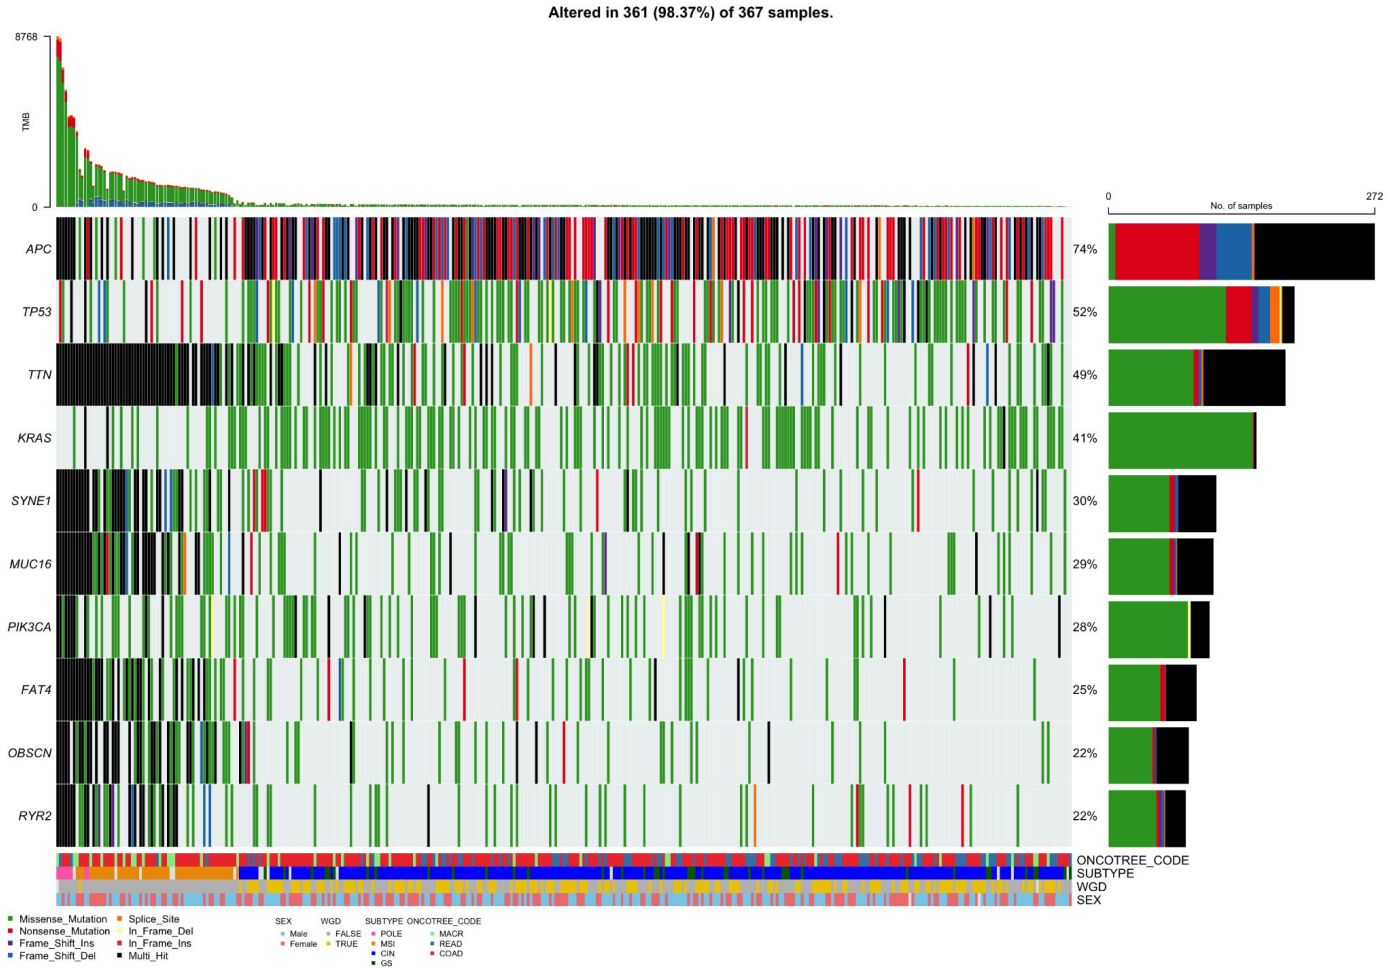
```
plotmafSummary(maf = maf,
addStat = "median")
```



¿Qué genes están recurrentemente mutados y cómo se distribuyen entre pacientes?

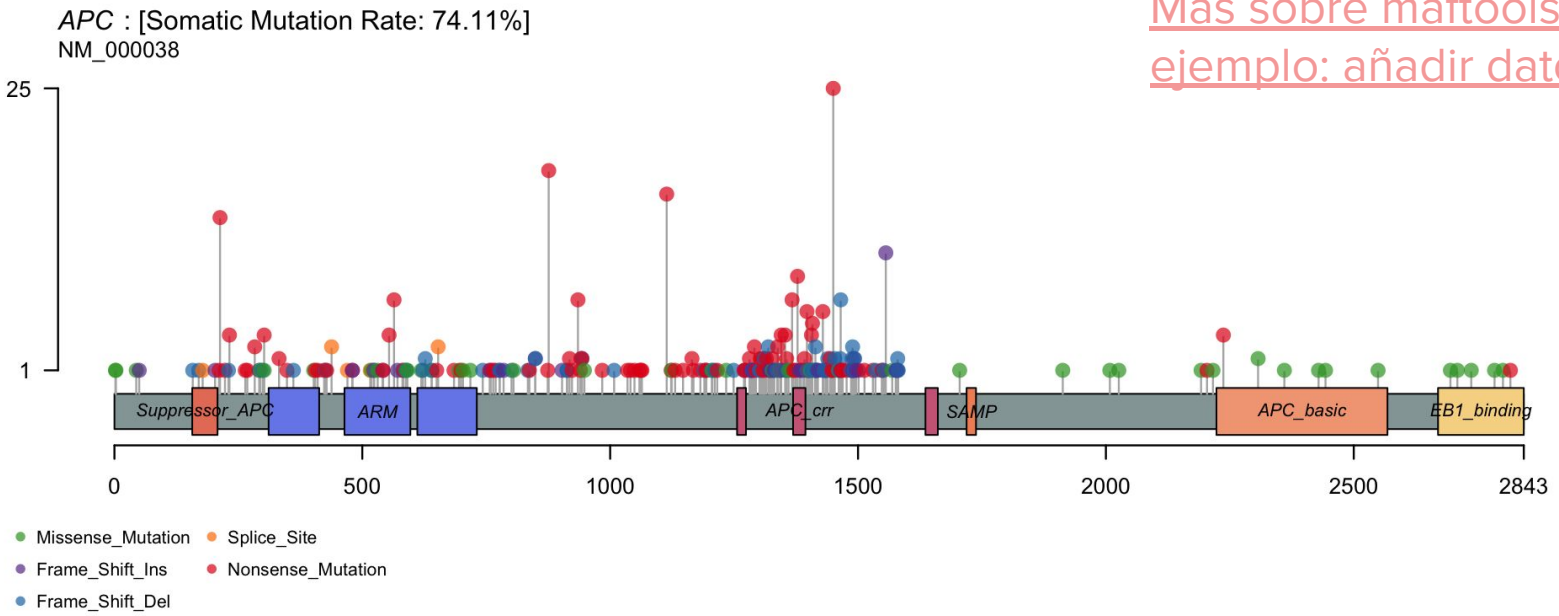
```
muestras_por_tmb <- metadata %>%
  filter(Tumor_Sample_Barcode %in% getSampleSummary(maf)$Tumor_Sample_Barcode) %>%
  arrange(desc(TMB_NONSYNONYMOUS)) %>%
  pull(Tumor_Sample_Barcode)

# oncoplot(maf = maf, top = 10, sampleOrder = muestras_por_tmb)
oncoplot(maf = maf, top = 10, sampleOrder = muestras_por_tmb,
         clinicalFeatures = c("ONCOTREE_CODE", "SUBTYPE", "WGD", "SEX"),
         annotationColor = list(
           ONCOTREE_CODE = c(COAD = "brown2", READ = "steelblue", MACR = "lightgreen"),
           SUBTYPE = c(POLE = "hotpink1", CIN = "blue", MSI = "orange2", GS = "darkgreen"),
           WGD = c("FALSE" = "gray", "TRUE" = "gold2"),
           SEX = c(Female = "lightcoral", Male = "skyblue")
         ),
         annotationFontSize = 0.8, legendFontSize = 1)
```


Altered in 361 (98.37%) of 367 samples.
8768
TMB
0
0
272
No. of samples
APC
TP53
TTN
KRAS
SYNE1
MUC16
PIK3CA
FAT4
OBSCN
RYR2
74%
52%
49%
41%
30%
29%
28%
25%
22%
22%
ONCOTREE_CODE
SUBTYPE
WGD
SEX
Missense_Mutation
Nonsense_Mutation
Frame_Shift_Ins
Frame_Shift_Del
Splice_Site
In_Frame_Del
In_Frame_Ins
Multi_Hit
SEX
Male
Female
WGD
FALSE
TRUE
SUBTYPE
POLE
MSI
CIN
GS
ONCOTREE_CODE
MACR
READ
COAD

¿Las mutaciones se distribuyen uniformemente a lo largo de un gen? Revisar las mutaciones en APC y KRAS

```
lollipopPlot(maf = maf, gene = "APC", AACol = "HGVSp_Short")
lollipopPlot(maf = maf, gene = "KRAS", AACol = "HGVSp_Short")
```

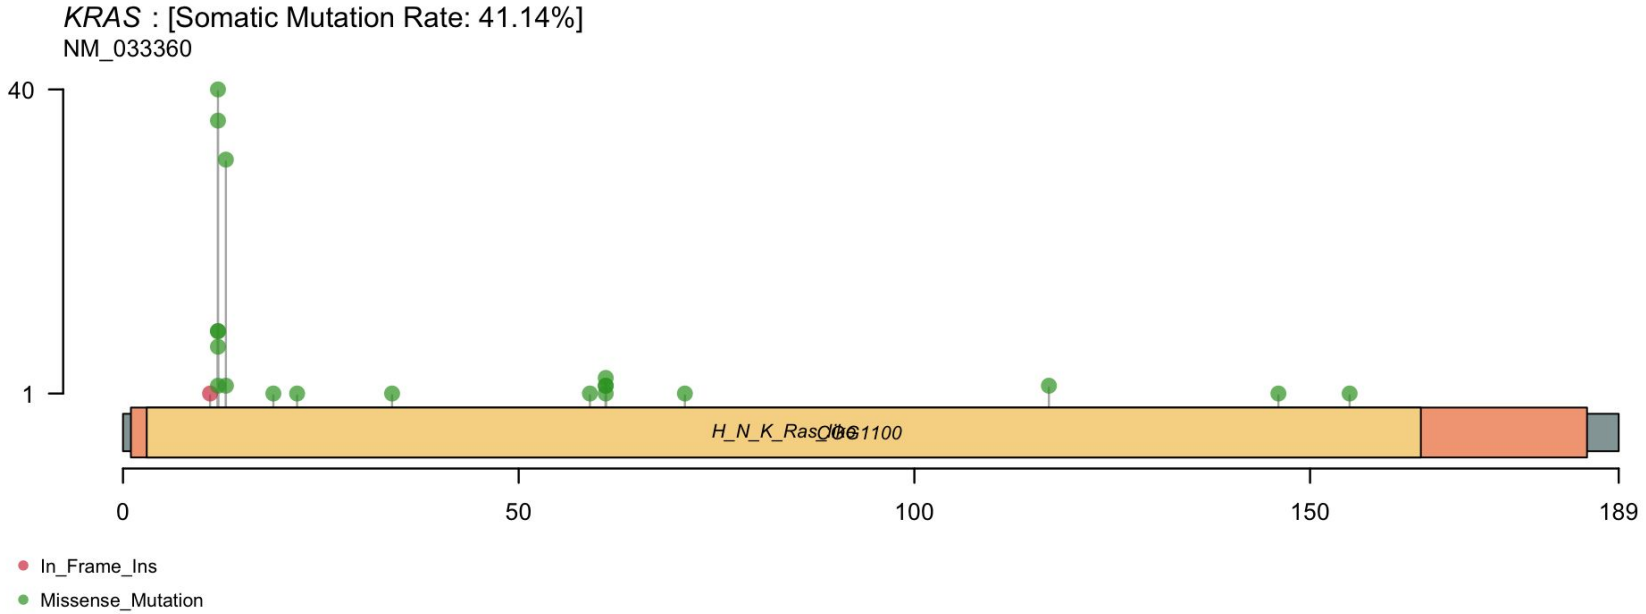


Más sobre maftools (por ejemplo: añadir datos de CNV)

HGVSp_Short describe ***el cambio que produce la variante en la proteína***

¿Las mutaciones se distribuyen uniformemente a lo largo de un gen? Revisar las mutaciones en APC y KRAS

```
lollipopPlot(maf = maf, gene = "APC", AACol = "HGVSp_Short")
lollipopPlot(maf = maf, gene = "KRAS", AACol = "HGVSp_Short")
```



HGVSp_Short describe ***el cambio que produce la variante en la proteína***

Taller práctico II

Extraer características resumen del MAF de cáncer colorrectal y generar una matriz gen x muestra almacenando la cantidad de mutaciones.

- Genere una tabla por muestra de cantidad de genes con *multi-hit.* ¿Se relaciona esto con el valor de TMB? ¿Con qué subtipo de cáncer colorrectal se relaciona el valor de multi-hit?
- Transforme la matriz a una matriz binaria de estado mutacional (TRUE o FALSE). Mediante el uso de regresión logística, establezca que mutaciones se asocian a un subtipo MSI. *Normalizar por pureza, sexo y edad.*
- ¿El estado mutacional de algún gen se relaciona con la ancestría global de los individuos?

Genere una tabla por muestra de cantidad de genes con *multi-hit.*

```
matriz_gen_muestra <- as_tibble(maf@data) %>%
  count(Hugo_Symbol, Tumor_Sample_Barcode, name = "n_mutaciones") %>%
  pivot_wider(names_from = Tumor_Sample_Barcode,
              values_from = n_mutaciones, values_fill = 0) %>%
  column_to_rownames("Hugo_Symbol") %>%
  as.matrix()

dim(matriz_gen_muestra)
```

```
[1] 17239   367
```

	TCGA-A6-2686-01	TCGA-AA-3663-01	TCGA-AM-5821-01	TCGA-AZ-4315-01	TCGA-CA-6717-01	TCGA-D5-6531-01
A1BG	1	1	1	1	1	1
A1CF	0	0	0	0	1	0
A2M	0	0	0	0	3	0
A2ML1	1	0	0	1	4	1
A3GALT2	0	0	0	0	0	0
A4GALT	0	0	0	0	0	0

Genere una tabla por muestra de cantidad de genes con *multi-hit.*

```
tabla_multihit <- tibble(
  Tumor_Sample_Barcode = colnames(matriz_gen_muestra),
  n_mutaciones = colSums(matriz_gen_muestra),
  n_genes_mutados = colSums(matriz_gen_muestra > 0),
  n_genes_multihit = colSums(matriz_gen_muestra >= 2)) %>%
  left_join(metadata %>% select(Tumor_Sample_Barcode, TMB_NONSYNONYMOUS, SUBTYPE),
            by = "Tumor_Sample_Barcode") %>%
  mutate(SUBTYPE = factor(SUBTYPE, levels = c("CIN", "MSI", "POLE", "GS")))

head(tabla_multihit)
```

A tibble: 6 × 6

Tumor_Sample_Barcode <chr>	n_mutaciones <dbl>	n_genes_mutados <dbl>	n_genes_multihit <dbl>	TMB_NONSYNONYMO... <dbl>	SUBTYPE <fctr>
TCGA-A6-2686-01	1969	1748	189	135.76667	MSI
TCGA-AA-3663-01	1855	1690	143	64.86667	MSI
TCGA-AM-5821-01	1124	1054	63	40.50000	MSI
TCGA-AZ-4315-01	6034	4330	1075	211.36667	POLE
TCGA-CA-6717-01	8768	5576	1785	320.76667	POLE
TCGA-D5-6531-01	163	159	4	5.70000	CIN

6 rows

¿Cómo determinamos la relación entre TMB-multihit y subtipos?

Modelo lineal (lm)

¿Qué hace?

Evalúa la relación entre una variable numérica y una o más variables explicativas.

En R:

```
modelo <- lm(
  n_genes_multihit ~ TMB_NONSYNONYMOUS,
  data = tabla_multihit
)
summary(modelo)
```

¿Cómo interpretarlo?

- **Estimate**: cambio esperado en Y por unidad de X
- **p-value**: evidencia de asociación
- **R^2**: proporción de variabilidad explicada

Kruskal-Wallis

¿Qué hace?

Compara una variable numérica entre tres o más grupos independientes.

En R:

```
kruskal.test(
  n_genes_multihit ~ SUBTYPE,
  data = tabla_multihit
)
```

¿Cómo interpretarlo?

- **p-value**: evidencia de diferencias entre grupos
- **Chi-squared**: estadístico del test
- **df**: grados de libertad



Interpretación común

Si $p < 0.05$, hay evidencia estadística contra la hipótesis nula. En Kruskal-Wallis, una prueba significativa indica que al menos un grupo difiere.

¿Se relaciona esto con el valor de TMB?

```
modelo_multihit_tmb <- lm(n_genes_multihit ~
TMB_NONSYNONYMOUS,
                          data = tabla_multihit)
resumen_modelo <- summary(modelo_multihit_tmb)

# El p-value prueba la asociacion de la pendiente; no
demuestra linealidad.
p_multihit_tmb <-
resumen_modelo$coefficients["TMB_NONSYNONYMOUS",
"Pr(>|t|)"]
r2 <- round(resumen_modelo$r.squared, 3)
p_valor <- signif(p_multihit_tmb, 3)
texto_regresion <- paste("Regresion lineal: R2 =", r2, ";
p =", p_valor)

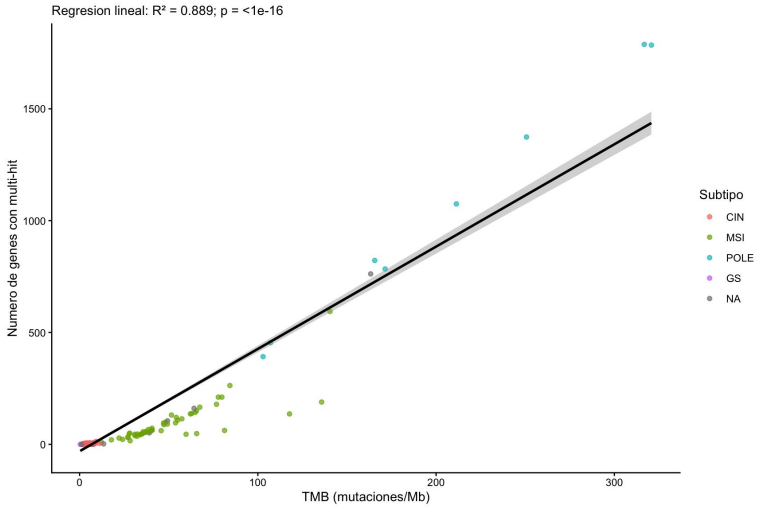
ggplot(tabla_multihit, aes(x = TMB_NONSYNONYMOUS, y =
n_genes_multihit)) +
  geom_point(aes(color = SUBTYPE), alpha = 0.7) +
  geom_smooth(method = "lm", formula = y ~ x, color =
"black") +
  labs(x = "TMB (mutaciones/Mb)", y = "Numero de genes con
multi-hit",
       color = "Subtipo", subtitle = texto_regresion) +
theme_classic()
```

```
Call:
lm(formula = n_genes_multihit ~ TMB_NONSYNONYMOUS, data = tabla_multihit)

Residuals:
    Min      1Q  Median      3Q     Max
-401.15    8.12   15.60   19.23  369.74

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)      -31.00753    3.41221  -9.087   <2e-16 ***
TMB_NONSYNONYMOUS   4.57517    0.08443  54.186   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 60.2 on 365 degrees of freedom
Multiple R-squared:  0.8894,    Adjusted R-squared:  0.8891
F-statistic:  2936 on 1 and 365 DF,  p-value: < 2.2e-16
```



¿Con qué subtipo de cáncer colorrectal se relaciona el valor de multi-hit?

```
resumen_multihit_subtipos <- tabla_multihit %>%
  filter(!is.na(SUBTYPE)) %>% group_by(SUBTYPE) %>%
  summarise(n_muestras = n(),
            mediana_multihit =
median(n_genes_multihit),
            .groups = "drop")

resumen_multihit_subtipos
kruskal.test(n_genes_multihit ~ SUBTYPE, data =
tabla_multihit)
ggplot(tabla_multihit %>% filter(!is.na(SUBTYPE)),
       aes(x = SUBTYPE, y = n_genes_multihit, fill =
SUBTYPE)) +
  geom_boxplot(outlier.shape = NA) +
  geom_jitter(width = 0.15, alpha = 0.5, size = 1) +
  scale_fill_manual(values = c(CIN = "blue", MSI =
"orange2",
                               POLE = "hotpink1", GS =
"darkgreen")) +
  labs(x = "Subtipo de cancer colorrectal", y =
"Numero de genes con multi-hit") +
  theme_classic()
```

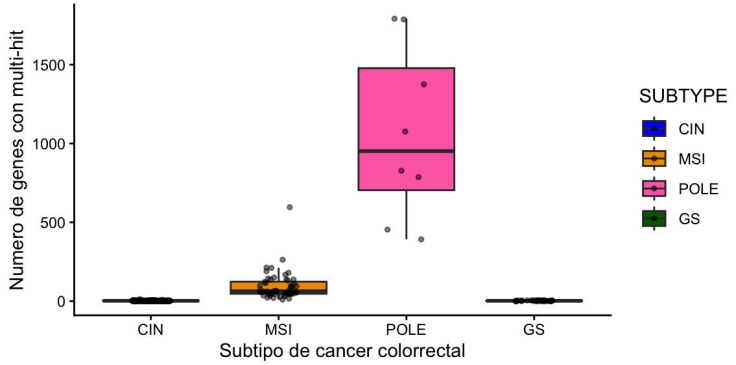
A tibble: 4 × 3

SUBTYPE <fctr>	n_muestras <int>	mediana_multihit <dbl>
CIN	252	2.0
MSI	52	62.5
POLE	8	948.5
GS	40	2.0

4 rows

```
        Kruskal-Wallis rank sum test

data:  n_genes_multihit by SUBTYPE
Kruskal-Wallis chi-squared = 154.49, df = 3, p-value <
2.2e-16
```



Transforme la matriz a una matriz binaria de estado mutacional (TRUE o FALSE).

```
matriz_binaria <- ifelse(matriz_gen_muestra > 0, TRUE, FALSE)
dim(matriz_binaria)
```

```
[1] 17239   367
```

```
metadata_msi <- metadata %>%
  select(Tumor_Sample_Barcode, SUBTYPE, purity, SEX, AGE) %>%
  filter(Tumor_Sample_Barcode %in% colnames(matriz_binaria)) %>%
  mutate(MSI = SUBTYPE == "MSI", SEX = factor(SEX))

# Muestras con subtipo, pureza, sexo y edad para los modelos.
metadata_msi <- metadata_msi %>% drop_na(MSI, purity, SEX, AGE)
table(metadata_msi$MSI)

# Filtrar por genes que tengan al menos 5 muestras mutadas
genes_modelo <- rownames(matriz_binaria)[rowSums(matriz_binaria) >= 5]
length(genes_modelo)
```

```
FALSE  TRUE
  296    52
```

```
[1] 10595
```

Regresión lineal

1 **¿Cuándo se usa?**

Cuando la variable respuesta es binaria
(por ejemplo: MSI sí/no, respuesta sí/no, mutado/no).



2 **Código en R**

```
fit <- glm(MSI ~ KRAS + AGE + SEX,
           data = datos,
           family = binomial)
```

- `glm()` ajusta un modelo lineal generalizado.

3 **Interpretación y significancia**

- **β (beta)**: coeficiente del modelo en escala log-odds.
- **OR = exp(β)**: Odds Ratio.
- **Odds Ratio (OR)**: cuántas veces cambian las odds del evento.
- **OR > 1**: mayor odds del evento.
- **OR < 1**: menor odds del evento.
- **OR = 1**: sin asociación.
- **p-value / FDR**: indican significancia estadística (después de corrección).

```
datos_msh2 <- metadata_msi
datos_msh2$MSH2 <- matriz_binaria["MSH2", datos_msh2$Tumor_Sample_Barcode]

modelo_msh2 <- glm(MSH2 ~ MSI + AGE + SEX + purity,
                   data = datos_msh2, family = binomial())

tabla_msh2 <- as.data.frame(summary(modelo_msh2)$coefficients)
tabla_msh2$OR <- exp(tabla_msh2$Estimate)

tabla_msh2
```

Description: df [5 × 5]

	Estimate <dbl>	Std. Error <dbl>	z value <dbl>	Pr(>|z|) <dbl>	OR <dbl>
(Intercept)	-3.09738240	1.58813941	-1.95032147	0.0511378147	0.04516728
MSITRUE	2.22888868	0.57468682	3.87844061	0.0001051282	9.28953672
AGE	-0.01686490	0.02021915	-0.83410556	0.4042214999	0.98327651
SEXMale	0.56199433	0.58752124	0.95655152	0.3387936674	1.75416741
purity	-0.08710902	1.59078687	-0.05475845	0.9563309066	0.91657717

5 rows

```
genes_modelo <- rownames(matriz_binaria)[rowSums(matriz_binaria) >= 10]
resultados_msi <- data.frame(gen = genes_modelo, beta = NA_real_, p_value = NA_real_)

for (i in seq_len(nrow(resultados_msi))) {
  datos <- metadata_msi
  datos$mutacion <- matriz_binaria[resultados_msi$gen[i], datos$Tumor_Sample_Barcode]

  # Ocultar los avisos; los controles de validez se mantienen debajo.
  modelo <- suppressWarnings(
    glm(mutacion ~ MSI + AGE + SEX + purity, data = datos, family = binomial())
  )

  if (modelo$converged && !anyNA(coef(modelo))) {
    coeficiente <- summary(modelo)$coefficients["MSITRUE", ]
    OR_gen <- exp(coeficiente["Estimate"])

    if (is.finite(OR_gen) && OR_gen > 0) {
      resultados_msi$beta[i] <- coeficiente["Estimate"]
      resultados_msi$p_value[i] <- coeficiente["Pr(>|z|)"]
    }
  }
}

resultados_msi$OR <- exp(resultados_msi$beta)
resultados_msi$FDR <- p.adjust(resultados_msi$p_value, method = "BH")
```

```
genes_significativos_msi <- resultados_msi %>%
  filter(FDR < 0.05) %>% arrange(FDR, gen)

# Beta > 0: mayor probabilidad de mutacion en MSI TRUE; beta < 0: mayor en MSI FALSE.
genes_msi_true <- genes_significativos_msi %>% filter(beta > 0)

print(paste("Total de genes asociados a MSI TRUE:", nrow(genes_msi_true)))

top10_msi_true <- genes_msi_true %>%
  slice_head(n = 10) %>% select(gen, beta, OR, p_value, FDR)
top10_msi_true
```

```
[1] "Total de genes asociados a MSI TRUE: 3760"
```

Description: df [10 × 5]

gen <chr>	beta <dbl>	OR <dbl>	p_value <dbl>	FDR <dbl>
KMT2B	3.248353	25.74790	9.583235e-17	5.076719e-13
KMT2D	3.233730	25.37413	6.801202e-17	5.076719e-13
BRAF	3.180726	24.06422	4.924746e-16	1.739256e-12
MYCBP2	3.634512	37.88337	8.417144e-16	2.097974e-12
RNF43	3.697727	40.35547	9.900774e-16	2.097974e-12
ANK3	3.194123	24.38877	1.373244e-15	2.424920e-12
ZFHX3	3.351558	28.54717	5.505444e-15	8.332882e-12
MUC5B	2.749980	15.64232	6.986547e-15	9.252809e-12
DNAH2	3.162664	23.63346	1.077935e-14	1.268969e-11
MACF1	3.050302	21.12172	1.450065e-14	1.536344e-11

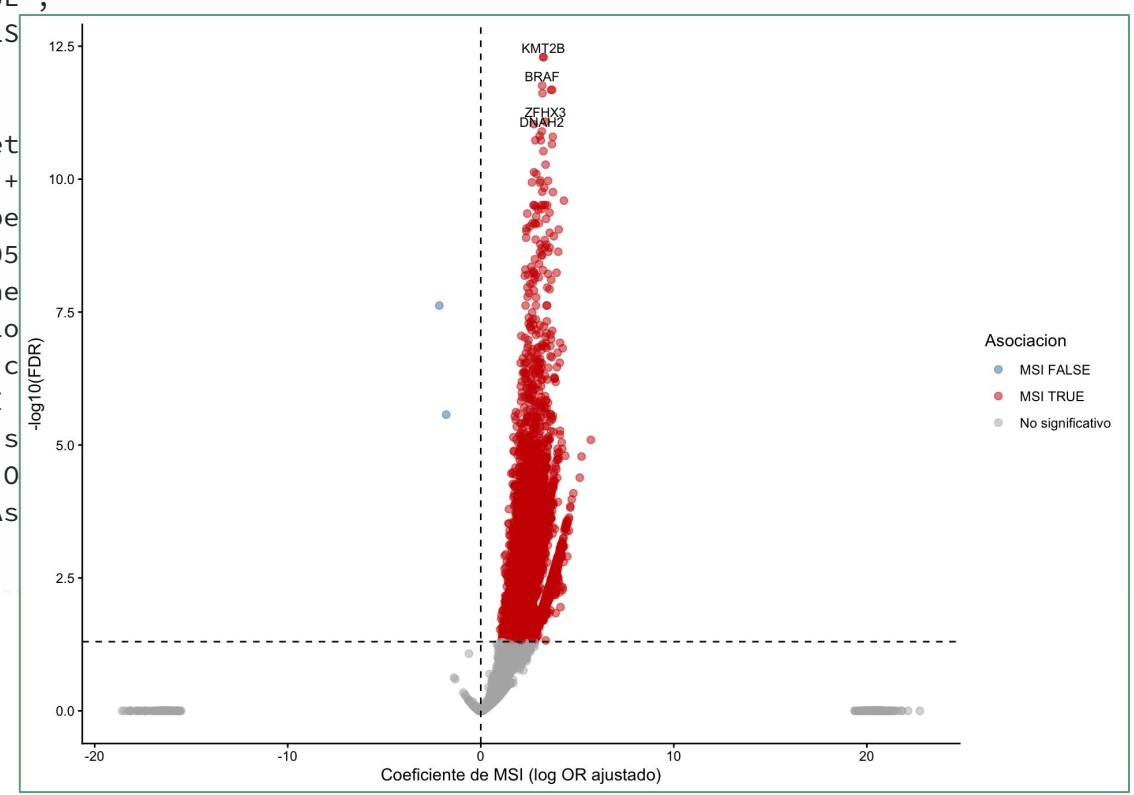
1–10 of 10 rows

```r
datos_volcano_msi <- resultados_msi %>%
  filter(!is.na(FDR)) %>%
  mutate(asociacion = case_when(
    FDR < 0.05 & beta > 0 ~ "MSI TRUE",
    FDR < 0.05 & beta < 0 ~ "MSI FALSE",
    TRUE ~ "No significativo"))

ggplot(datos_volcano_msi, aes(x = beta, y = -log10(FDR), color = asociacion)) +
  geom_point(alpha = 0.5, size = 2) +
  geom_vline(xintercept = 0, linetype = "dashed") +
  geom_hline(yintercept = -log10(0.05), linetype = "dashed") +
  geom_text(data = top10_msi_true, aes(x = beta, y = -log10(FDR), label = gen),
            inherit.aes = FALSE, color = "black",
            vjust = -0.5, size = 3, check_overlap = TRUE) +
  scale_color_manual(values = c("MSI TRUE" = "red3", "MSI FALSE" = "steelblue",
                                "No significativo" = "grey70")) +
  labs(x = "Coeficiente de MSI (log OR ajustado)",
       y = "-log10(FDR)", color = "Asociacion") +
  theme_classic()
```

```
datos_volcano_msi <- resultados_msi %>%
  filter(!is.na(FDR)) %>%
  mutate(asociacion = case_when(
    FDR < 0.05 & beta > 0 ~ "MSI TRUE",
    FDR < 0.05 & beta < 0 ~ "MSI FALS
    TRUE ~ "No significativo"))

ggplot(datos_volcano_msi, aes(x = bet
  geom_point(alpha = 0.5, size = 2) +
  geom_vline(xintercept = 0, linetype
  geom_hline(yintercept = -log10(0.05
  geom_text(data = top10_msi_true, ae
            inherit.aes = FALSE, colo
            vjust = -0.5, size = 3, c
  scale_color_manual(values = c("MSI
                                "No s
  labs(x = "Coeficiente de MSI (log O
       y = "-log10(FDR)", color = "As
  theme_classic()
```



¿El estado mutacional de algún gen se relaciona con la ancestría global de los individuos?

```
ancestria_europea <- read_tsv("../files/data_genetic_ancestry.txt",
                              show_col_types = FALSE) %>%
  filter(ENTITY_STABLE_ID == "EUR") %>%
  select(-ENTITY_STABLE_ID, -NAME) %>%
  pivot_longer(everything(), names_to = "Tumor_Sample_Barcode", values_to = "EUR") %>%
  mutate(EUR = EUR * 100)

metadata_ancestria <- metadata_msi %>%
  left_join(ancestria_europea, by = "Tumor_Sample_Barcode") %>%
  drop_na(EUR)

nrow(metadata_ancestria)
summary(metadata_ancestria$EUR)
```

```
[1] 333
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.001  86.089  95.074  79.259  98.655  99.996
```

```
resultados_ancestria <- data.frame(gen = genes_modelo,
                                   beta = NA_real_, p_value = NA_real_)

for (i in seq_len(nrow(resultados_ancestria))) {
  datos <- metadata_ancestria
  datos$mutacion <- matriz_binaria[resultados_ancestria$gen[i], datos$Tumor_Sample_Barcode]

  modelo <- suppressWarnings(
    glm(mutacion ~ MSI + AGE + SEX + purity + EUR,
        data = datos, family = binomial())
  )

  if (modelo$converged && !anyNA(coef(modelo))) {
    coeficiente <- summary(modelo)$coefficients["EUR", ]
    OR_gen <- exp(coeficiente["Estimate"])

    if (is.finite(OR_gen) && OR_gen > 0) {
      resultados_ancestria$beta[i] <- coeficiente["Estimate"]
      resultados_ancestria$p_value[i] <- coeficiente["Pr(>|z|)"]
    }
  }
}

resultados_ancestria$OR <- exp(resultados_ancestria$beta)
resultados_ancestria$FDR <- p.adjust(resultados_ancestria$p_value, method = "BH")
```

```
genes_fdr_ancestria <- resultados_ancestria %>%
  filter(FDR < 0.05) %>%
  arrange(FDR, gen)

print(paste("Genes con FDR < 0.05, mayor EUR:", sum(genes_fdr_ancestria$beta > 0)))
print(paste("Genes con FDR < 0.05, menor EUR:", sum(genes_fdr_ancestria$beta < 0)))
```

```
[1] "Genes asociados a mayor ancestria europea: 0"
[1] "Genes asociados a menor ancestria europea: 0"
```

```
genes_p_ancestria <- resultados_ancestria %>%
  filter(p_value < 0.05) %>%
  arrange(p_value, gen)

genes_mas_eur <- genes_p_ancestria %>% filter(beta > 0)
genes_menos_eur <- genes_p_ancestria %>% filter(beta < 0)

print(paste("Genes asociados a mayor ancestria europea:", nrow(genes_mas_eur)))
print(paste("Genes asociados a menor ancestria europea:", nrow(genes_menos_eur)))
```

```
[1] "Genes asociados a mayor ancestria europea: 6"
[1] "Genes asociados a menor ancestria europea: 110"
```

```
top10_mas_eur <- genes_mas_eur %>% slice_head(n = 10)
top10_menos_eur <- genes_menos_eur %>% slice_head(n = 10)

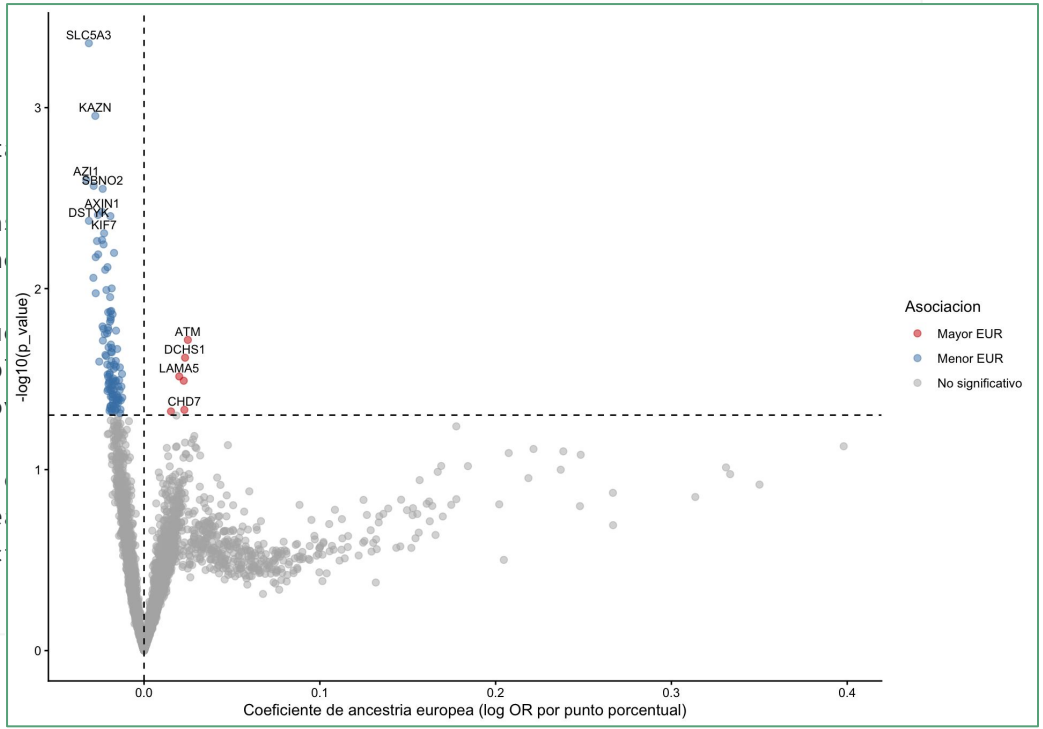
datos_volcano_ancestria <- resultados_ancestria %>%
  filter(!is.na(p_value)) %>%
  mutate(asociacion = case_when(
    p_value < 0.05 & beta > 0 ~ "Mayor EUR",
    p_value < 0.05 & beta < 0 ~ "Menor EUR",
    TRUE ~ "No significativo"))

ggplot(datos_volcano_ancestria, aes(x = beta, y = -log10(p_value), color = asociacion)) +
  geom_point(alpha = 0.5, size = 2) +
  geom_vline(xintercept = 0, linetype = "dashed") +
  geom_hline(yintercept = -log10(0.05), linetype = "dashed") +
  geom_text(data = bind_rows(top10_mas_eur, top10_menos_eur),
            aes(x = beta, y = -log10(p_value), label = gen),
            inherit.aes = FALSE, color = "black",
            vjust = -0.5, size = 3, check_overlap = TRUE) +
  scale_color_manual(values = c("Mayor EUR" = "red3", "Menor EUR" = "steelblue",
                                "No significativo" = "grey70")) +
  labs(x = "Coeficiente de ancestria europea (log OR por punto porcentual)",
       y = "-log10(p_value)", color = "Asociacion") +
  theme_classic()
```

```
top10_mas_eur <- genes_mas_eur %>% slice_head(n = 10)
top10_menos_eur <- genes_menos_eur %>% slice_head(n = 10)

datos_volcano_ancestria <- resultados_ancestria %>%
  filter(!is.na(p_value)) %>%
  mutate(asociacion = case_when(
    p_value < 0.05 & beta > 0 ~ "Mayor EUR"
    p_value < 0.05 & beta < 0 ~ "Menor EUR"
    TRUE ~ "No significativo"))

ggplot(datos_volcano_ancestria, aes(x = bet
  geom_point(alpha = 0.5, size = 2) +
  geom_vline(xintercept = 0, linetype = "da
  geom_hline(yintercept = -log10(0.05), lin
  geom_text(data = bind_rows(top10_mas_eur,
            aes(x = beta, y = -log10(p_valu
            inherit.aes = FALSE, color = "b
            vjust = -0.5, size = 3, check_o
  scale_color_manual(values = c("Mayor EUR"
                                "No signifi
  labs(x = "Coeficiente de ancestria europe
       y = "-log10(p_value)", color = "Asoc
  theme_classic()
```



Taller práctico III

Extraer características resumen del MAF de cáncer colorrectal y generar una matriz gen x muestra almacenando la cantidad de mutaciones.

- Genere una tabla por muestra de cantidad de genes con *multi-hit.* ¿Se relaciona esto con el valor de TMB? ¿Con qué subtipo de cáncer colorrectal se relaciona el valor de multi-hit?
- Transforme la matriz a una matriz binaria de estado mutacional (TRUE o FALSE). Mediante el uso de regresión logística, establezca que mutaciones se asocian a un subtipo MSI. *Normalizar por pureza, sexo y edad.*
    - *Opcional: realice un enriquecimiento funcional del listado de genes con clusterProfiler y base de datos Hallmark. ¿Qué procesos se ven afectados por las mutaciones en MSI?*
- ¿El estado mutacional de algún gen se relaciona con la ancestría global de los individuos?
- *Opcional: análisis de SBS*
    - *Obtenga las firmas mutacionales SBS de la cohorte y responda: ¿Qué firmas mutacionales están más representadas? ¿Se relaciona alguna con la ancestría genética? (Modelo lineal SBS ~ ancestría + covariables)*

Cómo obtener los SBS a partir del archivo MAF

```
# install.packages(c("sigminer", "nnls", "pheatmap"))
library(sigminer)
library(BSgenome.Hsapiens.UCSC.hg19)

# Matriz de 96 contextos usando el MAF ya generado.
tri <- trinucleotideMatrix(
  maf = maf, ref_genome = "BSgenome.Hsapiens.UCSC.hg19",
  prefix = "chr", add = TRUE, useSyn = TRUE)

sbs96 <- t(tri$nmf_matrix)

# Ajustar todas las firmas COSMIC SBS.
fit <- sig_fit(catalogue_matrix = sbs96, sig_index = "ALL",
               sig_db = "SBS", db_type = "human-exome",
               method = "NNLS", type = "absolute",
               return_error = TRUE, show_index = FALSE)

# Filas: muestras; columnas: firmas SBS.
sbs_absolute <- t(fit$expo)
totals <- rowSums(sbs_absolute)
sbs_relative <- sweep(sbs_absolute, 1, pmax(totals, 1), "/") * 100
sbs_relative[totals == 0, ] <- NA_real_
```

Cómo obtener los SBS a partir del archivo MAF

```
sbs_absolute # representa la cantidad de mutaciones asociadas a la firma
sbs_relative # representado en % de la actividad total

valid <- totals > 0
sbs_qc <- data.frame(
  Tumor_Sample_Barcode = rownames(sbs_absolute),
  total_activity = totals,
  cosine = fit$cosine,
  error = fit$errors,
  dominant_SBS = colnames(sbs_absolute)[max.col(sbs_absolute, ties.method = "first")]
)
sbs_qc$dominant_SBS[!valid] <- NA
head(sbs_qc)
```

	Tumor_Sample_Barcode <chr>	total_activity <dbl>	cosine <dbl>	error <dbl>	dominant_SBS <chr>
TCGA-3L-AA1B-01	TCGA-3L-AA1B-01	162	0.983972	7.806	SBS1
TCGA-4N-A93T-01	TCGA-4N-A93T-01	137	0.971015	7.803	SBS1
TCGA-4T-AA8H-01	TCGA-4T-AA8H-01	161	0.982613	8.604	SBS1
TCGA-5M-AAT4-01	TCGA-5M-AAT4-01	242	0.969071	12.566	SBS1
TCGA-5M-AAT5-01	TCGA-5M-AAT5-01	113	0.979336	6.571	SBS1
TCGA-5M-AAT6-01	TCGA-5M-AAT6-01	2388	0.996315	60.960	SBS1

FACULTAD DE MEDICINA
UNIVERSIDAD DE CHILE

Magíster en Informática Médica

Análisis de genomas de cáncer

Noemí Gómez
13 de octubre, 2026

noemi.gomez@postgrado.uoh.cl

La transcriptómica tumoral nos permite conocer el microambiente

